

2025.11–2026.06 HuggingFace 月榜 — Agentic RL 专题汇总

数据范围：HuggingFace Papers 月榜 **top 50**，2025-11 至 2026-06（共 8 个月）

标记：★ = 本专题精读 | 📄 = 基于摘要的简述 | 🔗 = 已在 `huggingface/` 周榜库精读，此处交叉引用

一、分类总览

Agentic RL = 「把 RL 的信用分配/奖励/探索机制，适配到 **agent** 的多轮、长程、工具交互轨迹上」。2025 H2–2026 H1 这条线已从「能不能用 RL 训 agent」走到「怎么把 rollout 成本、稀疏延迟奖励、多轮信用分配、技能内化做精细」。

主题	精读	简述	一句话定位
A. RL 算法 / 训练范式	01 DreamGym · 02 ERL · 03 OpenClaw-RL · 04 LLM-in-Sandbox	MEDS · DVAO · GrandCode🔗 · SDAR🔗	把"经验合成 / 反思 / next-state 信号 / 极简环境"做进 RL loop
B. Agent 自演化 & 经验	05 Agent0 · 06 EvoCUA · 07 CUDA Agent	MetaClaw · Agent-World · GroundCUA · GeoVista · Role-Agent · OpenGame · Thinking-with-Map · SWE-rebench-V2	自动合成环境/任务 + 大规模 rollout + 失败回收的自维持循环
C. Multi-Agent RL	08 HACRL · 09 MATTRL · 10 WideSeek-R1	SearchSwarm	异构互学 / 测试时协作 / 宽度扩展——MARL 的三种新解法
D. Deep Research /	11 IterResearch · 12 DR Tulu · 13 Harness-1	OpenSearch-VL🔗 · GrepSeek🔗 ·	长程上下文管理 + 可验证奖励 + 状态外置，是 DR 训练的三条主线

主题	精读	简述	一句话定位
Search Agent RL		Observation-Masking · DRIFT · MiroThinker🔗	
E. Skill RL	14 SkillRL · 15 SKILL0	Skill1🔗	把 skill 的发现/检索/内化统一进 RL，取代 inference-time 检索
F. 旗舰模型 (Agent RL 训练)	—	GLM-5🔗 · Kimi K2.5🔗 · Youtu-Agent🔗 · LongCat-Flash-Thinking	工业旗舰里 agentic RL 的工程化落地（异步 RL / Agent Swarm / Training-free GRPO）
G. Agent 安全 + RL	—	AgentDoG 1.5	安全对齐里用到 RL training

二、按月列出（每篇 800–1000 字详述，基于 arXiv 原文）

每篇展开为 800–1000 字，基于论文正文（method/实验节）撰写，覆盖问题动机 / 核心方法（含算法细节） / 关键结果（含具体数字与 ablation） / 意义与定位。★ = 本专题精读，📄 = 简短描述（已扩写），🔗 = 已在 huggingface/ 精读、此处交叉引用。

2025-11（14 命中 / 收录 9）

★ #17 Agent0: Self-Evolving Agents from Zero Data via Tool-Integrated Reasoning [UNC, 110↑] — arXiv 2511.16043

问题动机：LLM agent 用 RL 训练时严重依赖人类策划的数据——既限制规模，也把 AI 能力上限拴死在人类知识上。已有自演化框架有两大短板：受限于模型自身能力（自己出的题不会超过自己太多）、且多为单轮交互，难构造涉及工具使用/动态推理的复杂课程。

核心方法：Agent0 从同一个 base LLM（Qwen3-Base）初始化两个 agent——**Curriculum Agent π_θ** （出题者）与 **Executor Agent π_ϕ** （解题者）——做 T=3 轮共进化。每轮两阶段：① **Curriculum Evolution**——用 GRPO 训 π_θ 生成挑战冻结的 executor 的任务；② **Executor Evolution**——冻结 π_θ 、生成任务池、过滤出数据集 $\mathcal{D}$ ，再用 **ADPO** 训 π_ϕ 。**任务过滤**靠 self-consistency $\hat{p}(x)$ （k 个回答里多数票占比）： $\mathcal{D}=\{x: |\hat{p}(x)-0.5|\leq\delta\}$ ， $\delta=0.25$ （保留 $\hat{p}\in[0.3,0.8]$ 的"不太易也不太难"任务）。**Curriculum reward** 三信号：Uncertainty（ $R_{unc}=1-2|\hat{p}-0.5|$ ， $\hat{p}=0.5$ 时最大）+ Tool Use

($R_{\text{tool}} = \gamma \cdot \min(N_{\text{tool}}, C)$, $\lambda = 0.6$ 、 $\text{cap} = 4$, 鼓励工具调用) + Repetition Penalty (BLEU 聚类的任务相似度惩罚)。工具集成推理用"stop-and-go"多轮 rollout: 模型生成推理 → 输出 python → 暂停 → 沙箱执行 → output 回传 → 继续直到 \boxed{} 答案 (基于 VeRL-Tool)。关键算法 **ADPO**

(**Ambiguity-Dynamic Policy Optimization**) 在 GRPO 上加两点: **Ambiguity-Aware Advantage Scaling** (降权低一致性=噪声伪标签样本) + **Ambiguity-Modulated Trust Regions** (对模糊任务放松 upper clip ϵ_{high})。

关键结果: Qwen3-8B-Base 上**数学推理 +18%、通用推理 +24%**。数学 AVG: Base 49.2 → Agent0 58.2 (超 R-Zero 6.4%、Absolute Zero 10.6%、Socratic-Zero 3.7%); AIME24 13.9→28.0、AIME25 16.7→24.8。通用推理 8B: 34.5→42.1、4B: 27.1→37.6。**共进化进程证据:** 固定 executor 的 pass rate 逐轮 64.0→58.5→51.0 下降、平均 tool call 1.65→2.10→2.60 上升——证实"出题越来越难、解题越来越依赖工具"的良性循环 (8B 数学逐轮 55.1→56.5→58.2)。基准: 数学用 AMC/Minerva/MATH/GSM8K/Olympiad/AIME, 通用用 SuperGPQA/MMLU-Pro/BBEH。

意义: Agent0 证明 agent 可"自己造课程、自己出题、自己进化", 摆脱人类数据天花板。出题者-解题者对抗是优雅的 curriculum 自动化 (self-play 的课程版), ADPO 对"伪标签噪声"的处理是零数据自演化能稳定的关键。与同组 SkillRL 14-skillrl、MetaClaw 形成 UNC aiming-lab 的自演化 agent 系列, 与 DreamGym 01-dreamgym、EvoCUA 06-evocua 共享"自动造任务/环境"内核。精读见 05-agent0。GitHub github.com/aiming-lab/Agent0。

★ #33 DreamGym: Scaling Agent Learning via Experience Synthesis [Meta, 83↑] — arXiv 2511.03773

问题动机: RL 能通过交互增强 LLM agent, 但实际落地受阻于昂贵的 rollout、有限的任务多样性、不可靠的奖励信号、复杂的基建——这些都阻碍可扩展经验数据的收集。真实环境 rollout 慢、贵、奖励噪声大, 是 agent RL 工业落地的最大障碍。

核心方法: DreamGym 是首个为可扩展性设计、用合成经验做 **online agent RL** 的统一框架。核心是把环境动态蒸馏成一个 **reasoning-based experience model** (基于推理的经验模型) ——给定 (state, action), 模型通过 step-by-step 推理产生一致的状态转移与反馈信号, 替代昂贵的真实环境 rollout。三大组件: ① **Reasoning-based experience model**——不直接预测下一帧像素/HTML, 而是用语言推理刻画环境状态转移逻辑 ("点了提交→表单进入 pending→若字段缺失则报错"), 一次 LLM 前向代替一次真实容器执行; ② **Experience replay buffer**——用离线真实数据初始化、并持续用新交互补充, 提升 transition stability 与质量; ③ **Adaptive 课程**——经验模型自适应生成挑战当前 policy 的新任务, 实现 online curriculum learning。对照 RL 算法用 GRPO 与 PPO, 核心卖点是"用什么数据喂 RL"而非新 RL 算法。

关键结果: 在 WebArena 非 RL-ready 设定超所有基线 30%+; 在 RL-ready 但 rollout 昂贵的设定下, 仅用合成交互即媲美 GRPO/PPO; sim-to-real 迁移用远少于真实交互量获得显著额外增益。作者含

Jason Weston、Dawn Song、Bo Li (Meta, 18 作者)。

意义：DreamGym 把 agent RL 的成本从"维护真实环境集群"降到"训练 + 调用一个经验模型"，大幅降低复现门槛，确立 **world-model-for-RL** 在 LLM agent 语境下的可行性——经验模型用"推理"而非"像素生成"，避开传统 video world model 的保真度/成本难题。它与 EvoCUA [06-evocua](#) 形成 CUA/agent 降本两路（合成经验代替 rollout vs 规模化真实 rollout + 失败回收），是 2026 H1"绕过真实 rollout"潮流的源头。局限：经验模型的保真度上界决定一切，故仍需少量真实交互校准 sim-to-real gap。精读见 [01-dreamgym](#)。

★ #36 IterResearch: Long-Horizon Agents via Markovian State Reconstruction [阿里 Tongyi Lab, 80↑] — arXiv 2511.07327

问题动机：现有 deep-research agent 用 **mono-contextual** 范式（所有信息堆进单一膨胀上下文窗口），随任务推进（可达数百步）引发 **context suffocation**（上下文窒息）——有效信息被海量无关 token 稀释、推理容量被吃满——与 **noise contamination**（噪声污染）——早期失败路径、过时观测持续干扰后续决策。

核心方法：把长程研究重新形式化为 **MDP + 策略性工作区重建**。不做线性累积，而是维护一份 **evolving report**（演进报告）作为记忆——每隔若干步把已有信息合成为洞见写进报告、丢弃冗余原始内容，基于"重建后的紧凑工作区"继续决策，保证在任意探索深度下推理容量一致（不随步数退化）。训练侧配套 **EAPO (Efficiency-Aware Policy Optimization)**：用几何奖励折扣激励高效探索（早找到答案的轨迹奖励更高）+ **自适应下采样**稳定分布式训练。把"扩展"从"更大模型/更长上下文"转向"更多交互步数"——周期性重建让交互可扩展到 2048 步而不崩。

关键结果：6 个基准平均 **+14.5pp**；交互扩展到 **2048 次**时性能从 **3.5%** 飙升到 **42.5%**；即使只作为 **纯 prompting 策略**（不训练），也能让 frontier 模型在长程任务上比 ReAct **+19.2pp**。16 位作者（含 Wayne Xin Zhao、Pengjun Xie、Jingren Zhou），ICLR 2026 收录。

意义：IterResearch 给"上下文该不该装下一切"明确的否定回答——上下文是需要周期性 **curate** 的状态。它与 Harness-1 [13-harness-1](#) 的"状态外置"是同一病症（mono-context 膨胀）的两条解法（policy 周期性重建 vs 环境侧维护）。EAPO 把"高效探索"做进奖励设计，与 GrandCode 的难度自适应长度惩罚同属"用奖励塑形控制 agent 行为长度"。作为"深度扩展"代表，与 WideSeek-R1 [10-wideseek-r1](#)（宽度扩展）形成 DR scaling 双维坐标。精读见 [11-iterresearch](#)，亦是阿里通义 DeepResearch 系（[tongyi-deepresearch/](#)）与 [deep-research/02](#) 的核心。GitHub [github.com/Chen-GX/IterResearch](#)。

#4 MiroThinker: Interaction Scaling for Research Agents [MiroMind, 196↑] — arXiv 2511.11793

问题动机：开源 research agent 一直在 model size、context length 两维 scaling，但纯拉长推理链会退化（孤立运行、误差累积），社区缺一条可预测的第三 scaling 轴。

核心方法：MiroThinker 提出**第三个 scaling 维度——interaction scaling（交互规模）**：系统训练模型处理更深、更频繁的 agent-environment 交互。与 test-time scaling（推理链拉长）的本质区别——interactive scaling 靠**环境反馈 + 外部信息获取**纠错、refine trajectory，把"交互深度"确立为可预测的 scaling law。256K 上下文窗口下单任务可执行**最多 600 次 tool call**。tool-augmented research agent 用 RL 后训练提升单步工具使用可靠性。

关键结果：72B 变体在 **GAIA 81.9% / HLE 37.7% / BrowseComp 47.1% / BrowseComp-ZH 55.6%**——超过此前所有开源 agent，逼近 GPT-5-high。GitHub 8.2k★。

意义：MiroThinker 是开源 research agent 的奠基性工作，把"交互"提升为与 model size、context length 并列的第三 scaling 轴，为 IterResearch（交互推到 2048 次）、SearchSwarm（委派智能）等奠基。其 H1 版（验证嵌入推理）已在 `huggingface/12-mirothinker.md` 精读，本专题作为"interaction scaling"主线源头交叉引用（亦见 `deep-research/01`）。

#20 GroundCUA: Grounding Computer Use Agents on Human Demonstrations [ServiceNow, 107↑] — arXiv 2511.07332

问题动机：构建可靠的 computer-use agent 需要 **grounding**（把自然语言指令精确连到正确的屏幕元素）。web 和 mobile 交互有大量数据集，但**桌面环境的高质量 grounding 资源稀缺**。

核心方法：GroundCUA 基于**人类演示**构建桌面 grounding 数据集——记录真实用户在桌面环境的操作演示，提取"指令→屏幕元素"的精确对应关系。配套 GroundNext 模型，RL 用于优化 grounding 准确率——让 agent 准确把"点击保存按钮"这样的指令连到屏幕上正确的像素位置。

关键结果：在桌面 grounding 基准上显著提升 grounding 准确率（具体数字见论文）。GitHub github.com/ServiceNow/GroundCUA。

意义：GroundCUA 填补了桌面 CUA grounding 数据的空白——grounding 是 CUA 可靠执行的前提（连不对元素，再强的规划也白搭）。它偏数据基建，与 EvoCUA [06-evocua](#)（自动合成 CUA 经验）、huggingface/ 的 CUA-Suite/Video2GUI 形成 CUA 数据侧的多条路线（人类演示 grounding vs 自动合成 vs 挖视频），本专题作为 agent_train 数据侧工作列出（非精读）。

#24 GeoVista: Web-Augmented Agentic Visual Reasoning for Geolocalization [Tencent Hunyuan, 98↑] — arXiv 2511.15705

问题动机：现有 agentic 视觉推理多聚焦图像操作工具，缺乏更通用的 agentic 模型。地理定位此前多被当纯 retrieval 问题，但人类做法是"看图找路标→想区域→web 搜索确认/refine 假设"，是显式的工具增强推理过程。

核心方法：GeoVista 把地理定位重表述为 **agentic 任务**——在推理 loop 内无缝集成 **image-zoom-in 工具**（放大兴趣区域看清细节）与 **web-search 工具**（搜索路标/地名确认假设）。完整训练 pipeline = **cold-start SFT**（学推理模式与工具先验）+ **RL**（hierarchical reward 利用多层次地理信息——国家/城市/街道逐级奖励）。配套发布 **GeoBench** 基准（覆盖全球照片 + 全景图 + 卫星图三种视角）。

关键结果：大幅超过开源 agentic 模型，多数指标逼近 Gemini-2.5-flash / GPT-5。GitHub github.com/ekonwang/GeoVista。

意义：GeoVista 把"thinking with tool"原则具象到地理定位域，证明在专门任务上 agentic 设计（视觉 grounding + web 搜索 + RL）可超越纯 retrieval 范式并逼近 frontier 闭源。它与 huggingface/ 的 Thinking-with-Map（地图工具 agentic RL）同属"视觉 + web 工具 + RL"的地理定位路线，是多模态 deep research 在垂直任务上的代表（本专题作为 agent_train 简述，亦见 deep-research 月榜）。

2025-12 (17 命中 / 收录 2)

#1 From Code Foundation Models to Agents and Applications: A Practical Guide to Code Intelligence [Beihang, 305↑] — arXiv 2511.18538

问题动机：LLM 已根本性地改变自动化软件开发（GitHub Copilot、Cursor 等驱动商业采用），但 code intelligence 领域缺乏一份系统、实用的指南——从 code foundation model 到 coding agent 到应用的完整图景。

核心方法：这是一篇 **code intelligence 大综述/实用指南**，系统梳理从 code foundation model（代码基础模型）到 agents（agent 化）再到 applications（应用）的演进。含 coding agent 的 **RL 训练**章节——梳理 SWE agent 如何用 RL（SWE-RL、SkyRL 等）从真实 issue/repo 学习，以及数据构建、训练范式、关键挑战（长上下文、多文件 patching 一致性、回归测试）。

关键结果：提供 code intelligence 的术语体系、方法分类、技术总结与实践指南。

意义：本综述是 code intelligence/coding agent 方向的 reference，其 RL 训练章节对理解"coding agent 如何用 agentic RL 训练"有参考价值。本专题作为 coding-agent RL 的综述类工作列出（非精读），与 GrandCode（竞赛编程 agentic RL）、CUDA Agent [07-cuda-agent](#)（系统软件 agentic RL）等具体工作互补。

#13 ToolOrchestra: Elevating Intelligence via Efficient Model and Tool Orchestration [NVIDIA, 128↑] — arXiv 2511.21689

问题动机：LLM 是强大的通才，但解决 HLE (Humanity's Last Exam) 这类深而复杂的问题，既概念上困难又计算上昂贵——直接用最强大模型攻每道题成本过高。

核心方法：ToolOrchestra 证明小 **orchestrator (编排器)** 调度其他模型和工具可以高效攻克复杂问题。用 RL 训练一个轻量编排策略——它学会针对不同子问题动态选择最合适的模型/工具组合（便宜模型先试、失败再升级到强模型），以低成本逼近“全程用最强模型”的效果。

关键结果：在 HLE 等复杂基准上以显著更低成本达到有竞争力的表现（具体数字见论文）。GitHub github.com/NVlabs/ToolOrchestra。

意义：ToolOrchestra 把 agent 编排从“训练大模型当 router”推到“用 RL 训轻量 orchestrator”，更接近实际工业 latency/成本约束。它与 huggingface/ 的 SkillOrchestra (skill 感知路由) 同属“agent/工具编排”方向，本专题作为 orchestration + RL 的工作列出（非精读），核心 RL 贡献是“用 RL 学性能-成本权衡的编排策略”。

2026-01 (16 命中 / 收录 7)

★ #35 EvoCUA: Evolving Computer Use Agents via Scalable Synthetic Experience [美团, 92↑] — arXiv 2601.15876

问题动机：原生 CUA 的潜力被静态数据 **scaling** 的天花板卡住——主流做法是被动模仿静态数据集，覆盖不了真实操作的长尾。

核心方法：EvoCUA 把数据生成与 policy 优化合并为**自维持进化循环**。① **Verifiable Synthesis Engine**——“Generation-as-Validation”范式消除 reward hacking：层级域 taxonomy 把 app 分解为原子能力，ReAct VLM “Task Architect”**双流共生成指令流** g + validator 流 V_g (ground truth + 可执行评估代码)，闭环反馈在真实沙箱执行生成代码直到成功，配三重去污（语义/配置/评估器），扩到数万实例。② **可扩展基建**——基于 tools（不可变环境定义）+ clusters（动态扩展单元）抽象，异步 gateway 用 reactor 模式（每分钟数十万请求），burst scaling 一分钟拉起数万沙箱，持续**>100,000 并发沙箱**（QEMU-KVM VM 封进 Docker）。③ **Iterative Evolving Learning** 三阶段：**Cold-Start**（统一动作空间 + 结构化思维空间 + Hindsight Reasoning Generation）→ **RFT** (Dynamic Compute Budgeting：分层预算 $K^*=k_{\{i^*\}}$, $i^*=\min\{i:SR(k_i)\geq\tau_i\}$ ，把算力集中到**boundary queries** 高方差任务 + Step-Level Denoising) → **失败回收 RL (Step-Level DPO)**：Causal Deviation Discovery 定位 Critical Deviation Step t^* ，Paradigm I（在 t^* 做 Action Correction）+ Paradigm II（在 t^*+1 做 Reflection and Recovery，盲目续走=rejected、合成反思轨迹=chosen）。

关键结果：OSWorld EvoCUA-32B 56.7%（开源 SOTA，50 步），EvoCUA-8B 46.1%——超 OpenCUA-72B 45.0%（+11.7%）、UI-TARS-2 53.1%（+3.6%）、与 Claude-4.5-Sonnet（50 步 58.1%）差距缩到 1.4%；EvoCUA-8B 超同 backbone 的 Step-GUI-8B +5.9%。**Ablation**（32B，逐阶段 Δ ）：+统一动作空间 +4.84%、+Cold Start +2.62%、+RFT +3.13%、+Offline DPO +3.21%、+Iterative +1.90%。**经验 scaling**（OpenCUA-72B 纯 RFT）：20k +2.61pp $\rightarrow$ 226k +6.79pp $\rightarrow$ 1M +8.12pp。逾千次实验、超 100 万加速器小时。

意义：EvoCUA 把"环境自动合成 + 大规模并行 RL + 失败数据回收"整合为可持续运转的工业级 CUA 生产线，是 CUA 训练从"静态数据"到"自维持循环"的范式转变。失败回收（Step-Level DPO 定位关键分叉点）印证 2026 H1 共识——失败轨迹 = 高质量"诊断+修复"监督。与 DreamGym 01-dreamgym 形成 CUA 降本两路。精读见 06-evocua。GitHub github.com/meituan/EvoCUA。

★ #36 MATTRL: Collaborative Multi-Agent Test-Time RL for Reasoning [NUS / MIT, 92↑] — arXiv 2601.09667

问题动机：multi-agent RL（MARL）训练资源重且不稳定——队友 co-adapting 导致非平稳性，奖励稀疏且高方差。能否把 RL 的"经验积累"挪到推理时、不更新权重？

核心方法：MATTRL 把结构化文本经验注入多 agent 推理时审议，不更新任何权重。三阶段：① **Team formation**——coordinator 从预定义 specialist catalog（24 个医学科室）选团队（数学用"自由招募"）；② **经验增强对话达成共识**——同步多轮（max R=3），每个未收敛 specialist 检索经验（Qwen3-Embedding-4B + FAISS，top-K=8 余弦相似度，"EXPERIENCE HINTS"模板）、更新意见、通过"MEETING"聚合；③ **Report synthesis**——coordinator 综合证据出报告与最终决策（把证据聚合与决策分离）。**turn-level credit assignment：**每条发言由 LLM-judge 打分 $s_{i,t}$ ，团队结果 G 按衰减权重 $w_t = \gamma^{R-t}$ 回传， $r_{i,t} = \lambda s_{i,t} + (1-\lambda)G \cdot w_t \cdot c_{i,t}$ ；高价值发言（top 25%）被蒸馏成可检索文本。研究三种 **credit-assignment：**Naive（比例归一）/ Difference Rewards（反事实中和 agent i ）/ Shapley-style（Monte Carlo 排列的边际贡献）。

关键结果：医学（RareBench Task4）Hit@1 0.39/Hit@10 0.75/MRR 0.51（超 RareAgent-Refined 0.35/0.70/0.47）；数学（HLE）单 agent 0.27 $\rightarrow$ 多 agent 0.33 $\rightarrow$ MATTRL 0.36；教育（SuperGPQA）post 0.60 $\rightarrow$ 0.73 $\rightarrow$ **0.77**。整体比多 agent +3.67%、比单 agent +8.67%。**Credit ablation：**Difference Rewards 在严格精度上最优（Shapley"把功劳摊到联盟、有限排列下方差大、稀释决定性发言"），推荐 Difference 为默认。团队规模 Hit@1 在三 agent 时峰值（三 agent 比单 agent Hit@10 高约 14%）。

意义：MATTRL 提供 MARL 的零训练替代——在"训练式 MARL 太贵/不稳"场景，test-time 经验注入是实用解法。它把"经验积累 + 信用分配"剥离出权重训练，证明可纯靠文本机制在推理时实现（与 Youtu-Agent 的 Training-free GRPO 精神一致）。与 HACRL 08-hacrl（训练式异构）、WideSeek-R1 10-wideseek-r1（训练式宽度）构成 MARL 三种新解法——MATTRL 占据"测试时/零训练"一极。精读见 09-mattrl。GitHub github.com/zhiyuanhubj/MATTRL。

★ #38 LLM-in-Sandbox: Computer Environments Elicit General Agentic Intelligence [Microsoft Research, 87↑] — arXiv 2601.16206

问题动机：主流假设是"agent 必须配复杂 harness (LangChain/AutoGen 一大堆脚手架)"。但能否把计算机虚拟化为**仅含基础功能的 code sandbox**，就激发 LLM 的通用任务求解元能力？

核心方法：sandbox 是基于 Docker 的 Ubuntu 系统（单一 ~1.1GB 共享镜像），**仅三个工具**：bash（执行任意终端命令，作为安装包/引导功能的元工具）+ file_editor + finish，基础环境只有 Python + NumPy/SciPy，域工具交给模型自己装。**三大元能力**从交互中自然涌现：外部资源访问（如装 Java+OPSIN 转化学名）、文件管理（如对 100K+ token 报告先 grep/sed 再写 Python）、代码执行（如组合搜索解指令约束）。**LLM-in-Sandbox-RL 关键——只用非 agentic 数据**（普通问答/推理/选择题，来自 Instruction Pre-Training，与任何评测基准零重叠、不针对 coding）训练弱模型。**核心设计——context as files**：背景材料存成环境里的文件（多文档拆成 introduction.txt/methods.txt、单文件加 distractor）而非塞进 prompt，强制探索。RL 用 outcome-based reward（跟 DeepSeek-R1，整条轨迹按最终输出正确性给 rule-based 奖励），基于 rLLM/R2E-Gym/DeepSWE。

关键结果：7 模型评测，**强模型免训练**最大 +15.5%（Qwen3-Coder 数学 26.0→41.5），DeepSeek-V3.2 指令跟随 +14.4%、Claude-Sonnet-4.5 +12.7%、GPT-5 数学 +10.1%。**token 8x 缩减**（长上下文 Qwen3-Coder 102.9K→12.9K），总 token 仅 LLM 模式的 0.5–0.8x。**强弱分化**：强模型 External 6.2%/File 21.1%/Computation 12.5%、平均 12.6 turn；弱 Qwen3-4B 仅 0.8%/2.9%/2.9%、平均 23.7 turn（"乱逛"，数学反退 13.5%）。**RL 后**：Qwen3-4B sandbox 模式数学 32.5→53.3（+20.8）且迁移回纯文本模式，验证行为从 20.22→36.91 次/回答。**基建**：1.1GB 镜像 vs SWE-Gym 6TB，执行 <4% 总时间。

意义：LLM-in-Sandbox 质疑"agent 必须复杂 harness"的主流假设，给出"sandbox + RL"极简替代。与 Code as Agent Harness（huggingface/20）形成张力（后者论证代码是 substrate，本文论证最小化代码环境已足够），与 Harness-1 [13-harness-1](#) 构成"环境职责切分"两极（做薄 vs 做厚）。"非 agentic 数据即可训 agent"与 DreamGym 的"合成经验即可训 agent"共同降低 agent RL 数据门槛。精读见 [04-llm-in-sandbox](#)。

📄 #9 LongCat-Flash-Thinking-2601 Technical Report [Meituan LongCat, 181↑] — arXiv 2601.16725

问题动机：如何训出在 agentic 基准上达 SOTA 的大规模开源推理模型，同时兼顾计算效率？

核心方法：LongCat-Flash-Thinking-2601 是 **560B 参数 MoE 推理旗舰**，通过 **domain-parallel expert training + fusion**（领域并行专家训练 + 融合）的统一训练框架，在 agentic 基准上达 SOTA。把 **agentic search** 列为关键能力维度——模型具备多轮工具调用、tool-integrated reasoning 能力，用 RL 训练 multi-turn tool use 完成 deep research 类任务。

关键结果：在多个 agentic 基准上达开源 SOTA 级，agentic search 为其核心能力维度之一。GitHub github.com/meituan-longcat/LongCat-Flash-Thinking-2601。

意义：LongCat 代表"大规模 MoE 推理旗舰把 agentic search/tool use 作为一等能力、用 RL 训练"的趋势——DR/工具能力不再是外挂工程，而是旗舰训练时就内化的核心维度。本专题作为旗舰模型（agentic RL 训练）列出（非精读），与 GLM-5、Kimi K2.5、Step 3.5 Flash 同属"旗舰模型的 agentic 化"潮流。

#11 Thinking with Map: Reinforced Parallel Map-Augmented Agent [AMAP, 170↑] — arXiv 2601.05432

问题动机：现有 VLM 地理定位方法把它当 retrieval 问题，但人类做法是"看图找路标→想区域→看地图比对→缩小范围"，是显式的工具增强推理过程。

核心方法：让 VLM 在图像地理定位中像人类一样使用地图。① **Agent-in-the-map loop**——agent 显式调用地图工具（缩放/平移/对照路标），把每步地图截图作为新观察；② **两阶段训练**——agentic RL（GRPO 训 multi-step 地图工具使用）+ Parallel TTS（test-time 多个 agent 并行推断后投票）；③ 配套发布 **MAPBench** 基准（城市/农村/特殊地标场景）。

关键结果：Acc@500m（500 米误差内）从 8.0%（Gemini-3-Pro + Google Map baseline）提到 22.1%（提升近 3×）。

意义：Thinking with Map 把"thinking with tool"原则具象到地图域，证明在专门任务上 agentic 设计（地图工具 + GRPO + parallel TTS）可超越 frontier 闭源 + 工具的简单组合。它与 GeoVista（web 工具地理定位）同属"视觉 + 工具 + agentic RL"路线。本专题作为 agent_train 简述（亦见 [huggingface/00 W03](#)）。

#22 Youtu-Agent: Automated Generation + Hybrid Policy Optimization [Tencent, 119↑] — arXiv 2512.24615

问题动机：当下 agent 系统两大痛点——手工搭建 agent 太贵（数百 person-days）+ RL 训练成本极高（上万美元）。

核心方法：把 agent 的自动生成与持续优化端到端整合的开源框架。四件套：三层 YAML 框架（Agent/Tools/Env 解耦）+ 自动配置（Workflow 专家模板 + Meta-Agent 自动生成 YAML）+ **Training-free GRPO**（核心——用 LLM evaluator 把 group rollout 成败蒸馏成"语义 advantage"注入 textual LoRA，18击败10K 传统 RL）+ 端到端 Agent RL（基于 Agent-Lightning + VeRL，扩到 128 GPU）。

关键结果：WebShop/GAIA/SWE-bench Lite 等多基准达开源 SOTA；Training-free GRPO 相对 baseline 提升 8–15pp。

意义：Youtu-Agent 把"data synthesis + automated configuration + training-free optimization"做成完整工程闭环，是工业级 agent 框架代表。Training-free GRPO 与 MATTRL 09-matrl（测试时经验）同属"frozen model + 文本侧优化"。详见 [huggingface/05-youtu-agent.md](#)，本专题作为旗舰框架交叉引用。

#27 Let It Flow / ROME: Open Agentic Learning Ecosystem [AGI Lab, 109↑] — arXiv 2512.24873

问题动机：开源社区缺一个有原则的、端到端的生态来支撑 agentic crafting（agent 在真实环境多轮操作、迭代精炼产物）——训练框架、环境管理、上层 agent CLI 三者割裂。

核心方法：端到端开源 agent 生产基础设施 **ALE (Agentic Learning Ecosystem)**，三大组件：**ROLL**（后训练框架，统一 SFT/DPO/GRPO/PPO + agent rollout 高吞吐流水线）+ **ROCK**（沙盒环境管理器，一键拉起 terminal/browser/code execution 容器并暴露统一 step API）+ **iFlow CLI**（上层 agent 框架）。基于 ALE 训练 ROME 模型，配套 **IPA (Interaction-Perceptive Agentic Policy Optimization)** ——把 credit assignment 从"逐 token"提升到"语义交互块"粒度（一次 tool 调用 + 观察 = 一块），改善长程 trajectory 训练稳定性。100 万+ agent trajectory，发布 Terminal Bench Pro。

关键结果：完全开源（代码、权重、轨迹、环境镜像），IPA 显著改善长程训练稳定性、避免格式 token 主导梯度。GitHub github.com/alibaba/ROLL。

意义：ALE 填补"训练框架 + 环境管理 + 上层 CLI"三者割裂的空白，IPA 的"语义交互块粒度信用分配"与 GrandCode 的 Agentic GRPO、SDAR 的 token 门控同属"多轮信用分配精细化"主题。本专题作为开源 agent infra + RL 算法列出（非精读，亦见 [huggingface/00 W01](#)）。

2026-02 (20 命中 / 收录 6)

★ #42 SkillRL: Evolving Agents via Recursive Skill-Augmented RL [UNC, 76↑] — arXiv 2602.08234

问题动机：LLM agent 常孤立运作、不从过去经验学习。已有 memory-based 方法主要存 raw trajectory——冗长、冗余、噪声大，agent 提不出"高层、可复用的行为模式"，泛化受限。

核心方法：SkillRL 用自动技能发现 + 递归进化连接 raw experience 与 policy 改进。① **Experience-based Skill Distillation**——teacher（OpenAI o3）蒸馏 base agent（Qwen2.5-7B）轨迹，**同时保留成功与失败**：成功轨迹提策略模式 s^+ 、失败轨迹合成简洁教训 s^- （识别失败点、错误推理、正确动作、预防原则），10–20× token 压缩；② **层级 SkillBank**——General Skills（探索/状态管理/目标追踪等通用策略）+ Task-Specific Skills（域启发式/前置条件/失败模式），每个 skill 有 name/principle/when_to_apply；③ **Adaptive Retrieval**——通用 skill 恒含、任务特定按语义相似度 TopK（ $K=6$, $\delta=0.4$ ）；④ **Recursive Skill Evolution**——先 cold-start SFT 教会用 skill（仅给 skill"收益

有限"), SFT 后做 RL, 验证 epoch 后仅在 $\text{Acc}(C) < \delta$ 处触发演化 (diversity-aware 分层采样失败轨迹 $\rightarrow$ 生成新 skill), 形成良性循环。RL 用 **GRPO** (二元奖励、组归一 advantage、PPO clip + KL, $G=8$ 、LR $1e-6$)。

关键结果: **ALFWorld 89.9%** (超 **GRPO 77.6**, +12.3%)、**WebShop 72.7%** (超 **GRPO 66.1**); 超 GPT-4o 41.9%、Gemini-2.5-Pro 29.6%; 子任务 Cool +23.0%/Pick2 +22.8%/Heat +15%。7 个搜索 QA 平均 **47.1%** (超 Search-R1 38.5、EvolveR 43.1), Bamboogle 超 EvolveR +19.4%。**Ablation:** 去层级 -13.1%、去 skill 库 (用 raw 轨迹) -25%、去 cold-start SFT -20%、去动态演化 -5.5%。**技能库增长:** 55 skill (12 通用+43 特定) $\rightarrow$ 100 skill (Step 150); context $\sim$ 1300 vs raw memory $\sim$ 1450 token; >80% 成功仅需 60 步 (vs 无演化 90 步)。

意义: SkillRL 解决 memory-based agent 的核心痛点——raw trajectory 冗余、提不出可复用模式——用"蒸馏成 skill + 递归进化"替代"存原始轨迹", 库与 policy 共进化避免脱节。与 SKILL0 15-skill0 形成"skill $\times$ RL"两条路 (外部库共进化 vs 内化进参数)。与同组 Agent0 05-agent0 (能力共进化) 一脉。精读见 14-skillrl。GitHub github.com/aiming-lab/SkillRL。

★ #43 Experiential Reinforcement Learning (ERL) [USC / Microsoft, 75 $\uparrow$] — arXiv 2602.13949

问题动机: 环境反馈通常稀疏且延迟, LM 必须**隐式**推断"观察到的失败该如何转化为下次的行为改变"——这个隐式推断在长程任务极其低效。

核心方法: ERL 把 **experience-reflection-consolidation** 循环显式嵌入 RL。给定任务 x : ① **首次尝试** $y^{(1)} \sim \pi_{\theta}(\cdot|x)$, 得反馈 $f^{(1)}$ 、奖励 $r^{(1)}$; ② **门控反思** (仅当 $r^{(1)} < \tau=1$, 即只对失败/次优轨迹反思) ——生成 $\Delta \sim \pi_{\theta}(\cdot|x, y^{(1)}, f^{(1)}, r^{(1)}, m)$, m 是跨 episode 反思记忆存成功修正模式; ③ **第二次尝试** $y^{(2)} \sim \pi_{\theta}(\cdot|x, \Delta)$, 反思奖励 $\tilde{r}=r^{(2)}$, 若 $r^{(2)} > \tau$ 则存反思; ④ **Consolidation (内化)** ——用"selective distillation"只模仿成功的第二次尝试、且从输入移除反思: $L_{\text{distill}} = -E[\mathbb{I}(r^{(2)} > 0) \log \pi_{\theta}(y^{(2)}|x)]$, 训练模型仅凭原始 x 复现改进行为 (部署零额外推理开销)。**门控关键:** 对成功尝试反思会"鼓励 reward hacking"并让 off-policy 信号主导、破坏训练。RL 用 GRPO (rLLM 栈、 $8 \times H100$ 、Olmo-3-7B/Qwen3-4B、LR $1e-6$ 、KL 0.001、clip upper 0.28)。

关键结果: 基准 FrozenLake/Sokoban (稀疏奖励控制) + HotpotQA (agentic 推理)。**Sokoban Qwen3-4B 0.06 $\rightarrow$ 0.87 (+81%, 最大效应)**、Olmo3-7B 0.04 $\rightarrow$ 0.20; FrozenLake +27% (Qwen3 0.86 $\rightarrow$ 0.94); HotpotQA +11% (0.45 $\rightarrow$ 0.56)。**Ablation:** 完整 ERL > 无记忆 > 无反思 (去反思跌幅最大, Sokoban -0.28); 但 Olmo3-7B Sokoban 上无记忆略胜完整 ERL (+0.04), 说明自反思弱时持久记忆会传播早期坏反思。

意义: ERL 把"self-refinement"从推理时技巧转为训练时机制——成果内化、部署零开销。与 OpenClaw-RL 03-openclaw-rl 的 directive signal 同源 (都抽"该怎么改", ERL 靠自反思、OpenClaw-RL 靠 next-state hindsight), 与 DR Tulu 演化 rubric、MEDS 错误记忆构成"奖励信号丰富化"不同切

面。"helps most in environments requiring substantial reasoning about unknown dynamics"。精读见 [02-experiential-rl](#)。GitHub github.com/microsoft/experiential_rl。

#5 Kimi K2.5: Visual Agentic Intelligence [Moonshot, 273↑] — arXiv 2602.02276

问题动机：如何做一个开源多模态 agent 旗舰，让视觉与文本互相增强、并支持自主多步 agentic 行为？

核心方法：Kimi K2.5 强调文本与视觉的联合优化。完整 pipeline：joint text-vision pretraining（pretrain 阶段就联合，避免 visual encoder 后挂式对齐瓶颈）+ **Zero-vision SFT**（SFT 阶段不直接拿视觉数据微调，因视觉 SFT 损害预训练视觉鲁棒性，改为先纯文本 SFT）+ **joint text-vision RL**（RL 阶段同时优化文本与视觉任务，让视觉能力在 RLHF 中重新激活强化）。Agent 创新 **Agent Swarm**—— autonomous 并行编排，把任务分解为可并行子任务再调度多个 sub-agent，**延迟最高 -4.5x**。

关键结果：多模态 agent 评测（VisualWebArena/Mind2Web-Live/MMVet-Agent）开源 SOTA，接近 Claude 4.6 Sonnet。

意义：Kimi K2.5 把"多模态 + agent"做成可商用开源旗舰，joint text-vision RL 是其核心训练范式，Zero-vision SFT 是反直觉但被验证的关键技巧。详见 [huggingface/13-kimi-k25.md](#)，本专题作为旗舰模型（agentic RL 训练）交叉引用。

#22 GLM-5: from Vibe Coding to Agentic Engineering [Zhipu+清华, 151↑] — arXiv 2602.15763

问题动机：如何把"vibe coding"范式升级为"agentic engineering"，并证明开源旗舰可与闭源 frontier 同台竞技？

核心方法：GLM-5 是 744B 总参/40B-active MoE + MLA-256 + DSA 稀疏注意力，28.5T tokens 预训练。核心训练创新：① **异步 Agent RL**——基于自研 slime 框架，rollout 和 update 完全异步，512+ GPU 长时稳定运行；② **GRPO + IcePop 不对称 clip**——根据 advantage 符号采用不同 clip 阈值（positive 鼓励、negative 抑制）提升稳定性；③ 适配 7 个国产 GPU 平台。

关键结果：**BrowseComp 75.9**（断层领先所有开源，超 Claude Opus）+ **SWE-Verified 77.8** + **AAI v4.0 51.3**（首个 50+ 开源）。

意义：GLM-5 证明开源旗舰可与闭源 frontier 同台竞技，**异步 Agent RL + IcePop** 成为后续大模型训练事实标准。详见 [huggingface/06-glm-5.md](#)，本专题作为旗舰模型（agentic RL 训练）交叉引用——其异步 RL 与 OpenClaw-RL [03-openclaw-rl](#) 的异步架构、GrandCode 的 pipeline-RL 共同指向"rollout 与 update 解耦"成为大规模 agent RL 标配。

★ #30 WideSeek-R1: Width Scaling via Multi-Agent RL [清华 / RLinf, 100↑] — arXiv 2602.04634

问题动机：LLM 能力扩展过去主要走 depth scaling (单 agent 多轮)。但任务变广时瓶颈从"个体能力"转为"组织能力", 现有多 agent 系统靠手工 workflow + 轮流交互、无法有效并行。

核心方法：提出 **width scaling (宽度扩展)** —— 用一个共享 LLM 实例化为 lead agent + subagents, 但隔离上下文 + 专用工具。lead agent 用单一工具 `call_subagent` (故意受限以避免 context 污染), 每轮生成明确子任务并行派发、闲置等所有 subagent 完成。subagent 用 `search` + `access` 两工具并行跑, 结果去掉 thinking 后回传 (`Discard_think` 保持 lead context 短)。**MARL 算法**基于 GRPO 两点设计: ① **Multi-Agent Advantage Assignment**——可验证 outcome reward 组归一后, 同一 rollout 的所有 agent、所有 token 共享同一 advantage (避免复杂 credit assignment 导致 reward hacking); ② **Dual-Level Advantage Reweighting**——token-level (跨 turn, 跟 DAPO, 长 turn 不被稀释) + agent-level ("加 agent 只有提升最终 reward 才有益", 防止无意义 spawn)。Reward $R_i = r_{ans}(Item\ F1) + r_{format}(0.1) + r_{tool}(0.05) - r_{len}$ 。**20k 数据**用 gemini-3-pro 三阶段合成 (HybridQA 抽 intent → 10-50 行 query → 自一致性过滤, 阈值 0.9、去 <3 行表, 留存 73.28%, ~\$0.10/条)。

关键结果：WideSearch (200 任务, gpt-4.1 评) **WideSeek-R1-4B Item F1 40.0% (Max@4 51.8)** ——比单 agent SingleSeek-R1-4B +11.9%、比多 agent 基础 Qwen3-4B +8.8%, 4B/8B 中 6 项指标赢 5 项, 匹敌 DeepSeek-R1-671B (41.3) 但参数少近 170x。**Width scaling 行为：**depth scaling 快速饱和 (受固定上下文限制); base Qwen3-4B 宽度扩展到 10 subagent 时因冲突响应噪声反而下降; WideSeek-R1-4B 经 MARL 训练后持续增益, 10 subagent 时达 40% Item F1。训练时 lead 每轮最多调 10 个并行 subagent。

意义：WideSeek-R1 提出与"深度"正交的"宽度"scaling 维度, 证明 MARL 能训出真正的并行组织能力 (而非 prompt 拼装)。与 HACRL 08-hacrl、MATTRL 09-mattrl 构成 MARL 三种新解法——WideSeek-R1 占"宽度/并行组织"一极。与 IterResearch 11-iterresearch (深度)、SearchSwarm (委派) 共同构成 DR scaling 三个新轴。精读见 10-wideseek-r1, 亦是 deep-research/12。GitHub via RLinf。

📄 #32 Composition-RL: Compose Your Verifiable Prompts for RLVR [Tencent-Hunyuan, 94↑] — arXiv 2602.12036

问题动机：大规模可验证 prompt 支撑 RLVR 成功, 但含大量无信息样本、且进一步扩展昂贵。如何更好地利用有限训练数据?

核心方法：Composition-RL 组合可验证 prompt 来提升 RLVR 的数据效率——把现有可验证 prompt 按某种策略组合成新的、更有信息量的训练样本 (而非单纯采集更多 prompt), 在有限数据下榨取更多训练信号。属于 RLVR 的"数据侧"优化。

关键结果：在 RLVR 训练中以更高数据效率提升性能（具体见论文）。GitHub github.com/XinXU-USTC/Composition-RL。

意义：Composition-RL 与 F-GRPO（rare 样本）、GrandCode 的 reward 设计同属"RLVR 训练数据/信号侧精细化"，但聚焦"如何组合现有可验证 prompt 提升数据效率"。本专题作为 RLVR-data 工作列出（非精读），与 agentic RL 的关联在于其 tool-use rollout 与可验证奖励的数据构造。

2026-03（12 命中 / 收录 5）

★ #6 Heterogeneous Agent Collaborative Reinforcement Learning (HACRL) [Beihang 等, 198↑] — arXiv 2603.02604

问题动机：传统 multi-agent RL 要么同构 agent（共享参数）要么单向蒸馏（强→弱）。能否让**异构 agent**（不同架构/规模/专长）在训练时双向互学、推理时各自独立？难点是异构带来的能力差异 + 策略分布漂移会让朴素 advantage 共享有偏。

核心方法：HACRL 是新的 RLVR 范式——异构 agent **训练时共享已验证 rollout 互相提升、推理时独立**（n-agent 系统每条 rollout 可复用 n 次）。三类异构：Heterogeneous State（同架构不同权重）/ Size（同族不同规模）/ Model（不同架构/tokenizer/目标）。算法 **HACPO** 四机制：① **Agent-Capability-Aware Advantage Estimation**——用能力调整的 baseline， $A = (R - \mu) / \text{std}$ ， μ 把其他 agent 的奖励按能力比 $\omega^{\{k,j\}} = P_k / P^j$ 重加权；② **Model Capabilities Discrepancy Coefficient**——能力比也调制梯度（放大强 agent 信号、衰减弱 agent）；③ **Exponential Importance Sampling**——在 GSPO 序列级 ratio 上做跨 agent 非梯度指数重加权（tokenizer 不兼容则 detokenize+retokenize，Qwen/Llama 在 MATH 上 token 数仅差 ~4%）；④ **Stepwise Clipping**——cross-agent ratio（约[0.8,1.0]）与 self-ratio（约[0.9997,1.0004]）行为不同，bound 在 step 内渐紧。**理论：**oracle 能力感知 baseline 精确无偏（Theorem D.5: $E[\mu^*] = p^k$ ），有限 batch 给高概率误差界（Hoeffding+union bound）。

关键结果：7 个数学基准（MATH-500/MATH/GSM8K/AIME2025/AMC23/Minerva/Olympiad），比 **GSPO×2（双倍 rollout）平均 +3.6%、计算仅一半**。典型：Qwen3-4B State 0.691→0.755（+0.064）、AMC23 0.675→0.85、AIME2025 0.522→0.622；Llama3.2-3B Model 0.334→0.390（+0.056）、AMC23 0.175→0.35。5 seed 可复现（Qwen3-1.7B-Base MATH500 +3.56%）。

Ablation：去 Advantage Estimation 0.601→0.586；去 Stepwise Clipping → 严重不稳定；去 stepwise → 次优收敛。即使 Heterogeneous State 设定，弱 agent 也提供"alternative reasoning paths and informative errors"使强 agent 受益（非单向）。基于 verl，目前仅评测两 agent（基建限制， $n \geq 3$ 原理上支持）。

意义：HACRL 把"协作"从同构走向异构（不同模型架构/规模/专长），是 multi-agent RL 工程化的重要一步。"训练时协作、推理时独立"是实用解耦——既要协作红利又避开在线多 agent 协调成本。无偏 advantage 共享的理论保证为"异构 rollout 复用"提供地基。与 MATTRL [09-mattrl](#)、WideSeek-R1 [10-](#)

wideseek-r1 构成 MARL 三种新解法。与 GrandCode 的 Agentic GRPO、SDAR 共享"多轮/多 agent 信用分配精细化"主题。精读见 08-hacrl。

★ #12 OpenClaw-RL: Train Any Agent Simply by Talking [Princeton, 156↑] — arXiv 2603.10165

问题动机：每次 agent 交互都产生 **next-state signal** (用户回复/工具输出/终端 GUI 状态变化)，但没有现有 agentic RL 系统把它当作实时在线学习源。且 next-state 里既有评价信息也有改进方向，后者一直被浪费。

核心方法：OpenClaw-RL 基于"next-state 信号通用、policy 可对所有信号同时学"。两类信号：

Evaluative——PRM 每轮查 m 次投票 $\{+1, -1, 0\}$ ，多数票为标量奖励 r_t (re-query/纠正请求 = 负反馈)；

Directive——**Hindsight-Guided OPD**：PRM 检测到有意义纠正时把 s_{t+1} 蒸成 hint h

([HINT_START]...[HINT_END])，拼成 s_t^h ，取同模型 teacher 分布 $\pi_T(\cdot|s_t^h)$ ，对每个词 v 算 $w_v = \text{softmax}(\ell_{\text{old}})$ 、 $\Delta_v = \text{clip}(\ell_{\{T, h\}} - \ell_{\text{old}}, -C, C)$ 、 **$A_v = \Delta_v \cdot w_v$** (w_v 把 advantage 集中到学生可能采样的 token、clip bound 每 token log-prob 差)。**混合目标** $L^{\text{hybrid}} = w_{\text{RL}} \cdot L^{\text{GRPO}} + w_{\text{OPD}} \cdot L^{\text{OPD}}$

(默认各 1)。**Overlap-Guided Hint Selection**——按 top-k token 重叠 $O[h, i] = |S_i^q \cap S_{\{i, h\}}^p|$ 选 hint

(序列级在 agentic RL 更稳)。**Log-prob-difference clipping**——不 clip 时 Retool 设定截断率 0.5、

clip 后 0.2。**全异步架构**：环境 server / PRM judge / Megatron 训练 / SGLang 服务四者完全解耦、基于 slime，请求分 main-line turn (可训) 与 side turn (转发不训)，权重在同步边界推送、用户不等待。

关键结果：个人 agent (Qwen3-4B-Thinking，达优化所需最少 session，越低越好) Hybrid 平均 **10.3**

vs GRPO 14.1、OPD 29.7、Mem0 14.5、Cognitive 14.9——Hybrid 显著最优。**Qwen3-32B ablation**：

Seq-optimal 12.5 / Token-optimal 12.4 / Random 16.1 / GRPO 15.8 / OPD 29.9——证明 hint 选择关键、

token-level OPD 急剧退化。**通用 agentic RL** (PRM+Outcome vs Outcome-Only)：Tool-call

0.25 vs 0.19、GUI 0.33 vs 0.31。k ablation：k≥4 饱和 (默认 k=4)。并行环境 128 (terminal) / 64

(GUI/SWE) / 32 (tool-call)。

意义：OpenClaw-RL 把"训 agent"从"专家手工定义 reward"降到"普通对话/交互即监督"，是 agent

democratization 代表。**统一信号视角**——首次明确 terminal/GUI/SWE/对话是同一类 next-state 学习问

题，是"首个统一覆盖这些领域的真实 agent RL 框架"。directive 信号与 ERL 02-experiential-rl 殊途同

归 (都抽"该怎么改")。异步 RL 与 GLM-5 的 slime、GrandCode 的 pipeline-RL 共同指向"rollout 与

update 解耦"成标配。精读见 03-openclaw-rl。GitHub github.com/Gen-Verse/OpenClaw-RL。

★ #37 CUDA Agent: Large-Scale Agentic RL for CUDA Kernel Generation [ByteDance Seed, 99↑] — arXiv 2602.24286

问题动机：GPU kernel 优化是最专家化的系统软件任务，LLM 在通用编程强、但写 CUDA 一直打不过基于编译器的系统 (torch.compile)。如何用 agentic RL 反超？

核心方法：三件套。① **数据合成 pipeline (CUDA-Agent-Ops-6K)** ——Seed Crawling (从 torch/transformers 挖参考算子) → Combinatorial Construction (LLM 采样 ≤ 5 个算子堆叠成融合多算子任务, 因为"组合问题往往不等于逐个优化再拼接") → Filtering (Eager+Compile 都能跑、无随机性、anti-hacking、eager 1–100ms), ground-truth 用每题 5 个随机输入验证 (KernelBench 协议), AST 相似度 >0.9 去污。② **技能增强 CUDA 环境** ——基于 OpenHands ReAct loop, [SKILL.md](#) 规范"profile.py 分析→model_new.py 实现→GPU 沙箱编译评估→迭代直到比 torch.compile 快 $\geq 5\%$ 且数值正确", 奖励 $re\{-1,1,2,3\}$ (正确性失败 -1、同时快过 eager 和 compile 3、快过 eager 2、否则 1), 五重 anti-hacking。CPU-GPU 解耦 —— Docker 编译 + **128 张 H20 GPU** 验证/profiling。③ **高方差奖励稳定化** ——根因: 初版只稳训 17 步 (CUDA 代码 $<0.01\%$ 预训练数据、token 概率近精度下限、BF16/FP16 不匹配让 importance ratio 爆炸)。多阶段 warm-up (稳训到 200 步): Single-Turn Warm-up (PPO) → Actor Init (RFT 只留正奖励轨迹) → Critic Init (Value Pretraining, $\gamma=1/\lambda=0.95$)。RL 用 PPO 非对称 clip ($\epsilon_{low}=0.2/\epsilon_{high}=0.28$), Base=Seed1.6 (23B active/230B MoE)。

关键结果：KernelBench **Faster Rate vs torch.compile: L1 97.0%/L2 100%/L3 90%** (overall 96.8%), 远超 Claude Opus 4.5 (66.4%) / Gemini 3 Pro (69.6%); **L3 90% vs ~50–52%, 约 +40%**。Geomean 加速 overall $2.11\times$ (vs $1.46\times/1.42\times$), L2 达 $2.80\times$ 。Pass Rate L1/L2 100%、L3 94%。**Ablation:** w/o Agent Loop 96.8%→14.1%、w/o Robust Reward →60.4%、w/o RFT →49.8% (去 RFT"奖励灾难性崩溃 + 熵激增")、w/o Value Pretraining →50.9% ("轨迹长度爆炸")。注: GPT-5 系列"一律拒绝回应 CUDA 提示"未评测。

意义：CUDA Agent 证明 agent 可在系统软件开发 (CUDA 这种最专家化领域) 超越 frontier 闭源, 预示 AI 自动优化 GPU 代码成为新现实。与 GrandCode 一道确立"有可靠自动 verifier 的领域, agentic RL 能反超闭源" —— 把可验证性作为成功核心前提。与 EvoCUA [06-evocua](#)/Agent-World 共享"可验证环境 + 大规模 agentic RL"范式跨域复制。精读见 [07-cuda-agent](#)。GitHub github.com/BytedTsinghua-SIA/CUDA-Agent。

#24 MetaClaw: An Agent That Meta-Learns and Evolves in the Wild [UNC, 140↑] — arXiv 2603.17187

问题动机：部署的 LLM agent 往往保持静态、不随用户需求演化, 造成"持续服务 vs 更新能力"的张力 —— 现有方法要么囤积 raw 轨迹、要么用静态 skill 库、要么强制中断停机重训。

核心方法：MetaClaw 是持续 meta-learning 框架, 联合演化 base LLM policy + 可复用 skill 库, 两个互补机制: ① **Skill-driven fast adaptation** —— "LLM evolver"检视失败轨迹合成新 skill, 零停机立即改进; ② **Opportunistic policy optimization** —— 通过 cloud LoRA fine-tuning + **RL-PRM** (带 Process Reward Model 的 RL) 做梯度更新 (PRM 给中间推理步打分, 而非只奖励最终结果)。二者互相强化 (更好 policy 产更好轨迹供 skill 合成, 更丰富 skill 喂更高质量数据回 policy 优化)。**OMLS (Opportunistic Meta-Learning Scheduler)** 监控系统不活跃 + 日历数据, 在用户空闲窗触发重更

新；versioning 分离 support/query 数据防污染；proxy 架构让它"无需本地 GPU 即可扩到生产级 LLM"。

关键结果：skill-driven 适应**最高 +32% 相对增益**；Kimi-K2.5 准确率 **21.4%→40.6%**；复合鲁棒性 **+18.3%**。基准 MetaClaw-Bench、AutoResearchClaw。平台处理"20+ 渠道的多样工作负载"。13 作者。

意义：MetaClaw 把"部署中持续演化"工程化——零停机 skill 适应 + 空闲窗机会式 policy 优化 (RL-PRM)。它与 OpenClaw-RL [03-openclaw-rl](#)"被使用即训练"、同组 Agent0 [05-agent0](#)/SkillRL [14-skillrl](#) 一脉，是"agent 在真实部署中自演化"的代表。本专题作为 agent_train 简述。GitHub github.com/aiming-lab/MetaClaw。

#48 SWE-rebench V2: Language-Agnostic SWE Task Collection at Scale [Nebius, 89↑] — arXiv 2602.23866

问题动机：SWE agent 的近期进步很大程度由 RL 驱动，但 **RL 训练受限于"大规模、可复现执行环境、可靠奖励"的任务集稀缺**——尤其跨多语言。

核心方法：SWE-rebench V2 是**语言无关、大规模的 SWE 任务集**——为 SWE agent RL 提供可复现执行环境 + 可靠奖励信号的任务。它把真实 issue/repo 自动挖掘、构建可执行验证环境、覆盖多种编程语言，解决 RL 训练 SWE agent 的数据瓶颈。

关键结果：提供大规模、语言无关、可复现的 SWE RL 任务集（具体规模见论文）。GitHub github.com/SWE-rebench/SWE-rebench-V2。

意义：SWE-rebench V2 是 SWE agent RL 的数据基建——RL 训练的瓶颈是"任务稀缺 + 环境不可复现 + 奖励不可靠"，它三者一并解决并扩到多语言。与 Agent-World、CUDA Agent [07-cuda-agent](#) 的可验证环境合成同属"为 agentic RL 造可验证任务/环境"主线。本专题作为 agent_train 数据侧简述。

2026-04 (16 命中 / 收录 5)

#1 GrandCode: Grandmaster Competitive Programming via Agentic RL [Deep Reinforce, 632↑] — arXiv 2604.02721

问题动机：竞赛编程是人类对抗 AI 的最后堡垒之一——此前最强 AI (Gemini 3 Deep Think) 仅第 8 名且非直播。能否让 AI 在 Codeforces 直播赛击败所有人类？

核心方法：GrandCode 是 4 组件多 agent RL 系统： **π_{main}** (Qwen-3.5-397B 主求解) + **$\pi_{\text{hypothesis}}$** (27B 提结构性猜想，小样例 brute-force 验证， r_{verify} =通过测试占比，联合训练加下游项 $\beta(S(x,h)-S(x,\emptyset))$) + **π_{summary}** (27B 压缩超长 reasoning) + **Test Case Generator** (adversarial/solution-attack/large-size)。核心算法 **Agentic GRPO 两阶段更新**：对 multi-stage

rollout $s_1, r_1, \dots, s_N, r_N$ — **Immediate Reward** (r_t — 可得就更新, $A_t = (r_t - \mu_t) / \sigma_t$) + **Delayed Correction** (r_N 到时 $\delta_t = r_N - r_t$, $A_t = (\delta_t - \mu_t) / \sigma_t$)。三阶段 reward: Executability (编译失败 0) → Correctness (输出 ≠ 参照 0) → Efficiency (相对 brute-force 加速比, 超时 0.1)。Hypothesis-Guided Generation 可查 OEIS。

关键结果: Codeforces Round 1087/1088/1089 直播全部第一、全部最先完成。100 题 benchmark: full RL **81% accept/72.3 加权**、+test-time RL **85%/73.5** — 超 Gemini 3.1 Pro (64.3) / Claude Opus 4.6 (63.7) / GPT-5.4 (63.0)。Ablation 进程: base 52.2 → +continue 61.0 → +SFT 62.5 → +Full RL 72.3 → +Test-time RL 73.5。Hypothesis pass@1: 34% → 52%; 测试用例生成 42 → 48 → 50。

意义: GrandCode 证伪 "AI 永远做不过人类竞赛选手", **Agentic GRPO 成为后续 SDAR/DeITA 等的新基线** — 本专题 RL 算法的旗舰参照。"agentic RL + 强验证 + 在线适应能把编程系统推过最强人类"。详见 [huggingface/01-grandcode.md](#), 本专题交叉引用。

#23 MEDS: Memory-Enhanced Dynamic Reward Shaping [144↑] — arXiv 2604.11297

问题动机: RL 训练 LLM 的一个常见失败模式是 **采样多样性下降** — policy 反复生成相似的错误行为。经典 entropy 正则鼓励随机性, 但不显式惩罚跨 rollout 反复出现的错误模式。

核心方法: MEDS (Memory-Enhanced Dynamic reward Shaping) 把历史行为信号纳入 reward 设计。① 存储并利用历史 rollout 的 **中间模型表示** 捕捉过去 rollout 的特征; ② 用 **密度聚类** 识别频繁复现的错误模式 (如某种数学陷阱反复掉进去); ③ 落入高频错误簇的新 rollout **加重惩罚** — 形成 "教训越深、避免越急" 的动态 reward shaping。

关键结果: 5 数据集 × 3 base 模型, **pass@1 +4.13**、**pass@128 +4.37** — 单次和多次采样都提升, 说明既学到正确答案又增加多样性。GitHub [github.com/Linxi000/MEDS](#)。

意义: MEDS 把 "经验" (历史错误) 作为 reward shaping 信号, 避免 RL 训练陷入 "局部最优 + 重复犯错" 死循环。它与 ERL [02-experiential-rl](#) (反思记忆)、SDAR (门控) 同属 "用 token/历史级统计定位并修正 RL 问题", 是 RLVR 工具箱的实用补丁。本专题作为 rl_algo 简述 (亦见 [huggingface/00W16](#))。

#46 Agent-World: Scaling Real-World Environment Synthesis [ByteDance Seed, 85↑] — arXiv 2604.18292

问题动机: LLM 越来越被期望作为通用 agent 与外部有状态工具环境交互, 但训练受限于 **真实环境稀缺 + 缺乏有原则的终身学习机制**。MCP 与 agent skill 提供了统一接口, 但如何规模化合成可验证环境?

核心方法: Agent-World 是 **自演化训练竞技场**, 通过可扩展环境推进通用 agent 智能。两组件: ① **Agentic Environment-Task Discovery** — agent 自主探索数千真实环境主题的主题对齐数据库 + 可

执行工具生态，合成可验证、难度可控的任务；② **Continuous Self-Evolving Agent Training**——多环境 RL + 自演化竞技场（自动通过动态任务合成识别能力缺口），实现 **agent policy** 与环境的协同进化。

关键结果：23 个高难 agent 基准，**Agent-World-8B/14B** 一致超越强专有模型和环境 **scaling** 基线；分析显示性能随环境多样性和自演化轮数的 **scaling** 趋势。20 作者（Guanting Dong 等）。

意义：Agent-World 把"自演化环境合成"工程化为基础设施级 capability——agent 自己发现数据/工具、合成可验证任务、在竞技场识别缺口、policy 与环境共进化。它把 TermiGen/EvoCUA 06-evocua 的"环境合成"推到大规模通用化，与 DreamGym 01-dreamgym（合成经验）共同代表"为 agentic RL 造可验证环境/经验"主线。本专题作为 agent_train 简述。

#49 OpenGame: Open Agentic Coding for Games [81↑] — arXiv 2604.18394

问题动机：游戏开发处于创意设计与复杂软件工程的交叉点，需要协调游戏引擎、实时循环、跨多文件紧耦合状态。LLM/code agent 能解孤立编程任务，但被要求从高层设计产出**完整可玩游戏**时持续翻车——崩于跨文件不一致、场景接线断裂、逻辑不连贯。

核心方法：OpenGame 是首个端到端网页游戏创建 **agentic** 框架。核心是 **Game Skill**（可复用、可演化能力）：**Template Skill**（从经验积累项目骨架库，scaffold 稳定架构）+ **Debug Skill**（维护"已验证修复的活协议"，系统性修复集成错误而非补孤立语法 bug）。模型 **GameCoder-27B** 三阶段：**CPT**（持续预训练）→ **SFT** → **执行驱动 RL（execution-grounded RL）**。评测 **OpenGame-Bench**——因"验证交互可玩性比检查静态代码本质上更难"，用无头浏览器执行 + VLM 评判三维度：**Build Health / Visual Usability / Intent Alignment**。

关键结果：150 个多样游戏 prompt 上 **OpenGame** 建立新 **SOTA**（具体分数见论文）。

意义：OpenGame 把 coding agent 从"补全片段"推到"创造完整产品"，是 generative game 领域代表。其"Template/Debug Skill + 执行驱动 RL"展示了 agentic RL 如何训练"产出完整可运行应用"的能力。与 OpenGame-Bench 的"无头浏览器 + VLM 三维评判"对"难验证产物"的评测有借鉴。本专题作为 agent_train 简述。GitHub github.com/leigest519/OpenGame。

★ #39 SKILL0: In-Context Agentic RL for Skill Internalization [浙大, 101↑] — arXiv 2604.02268

问题动机：agent skill（推理时动态加载的过程知识包）已成 augment LLM agent 的可靠手段，但 inference-time 加载有三大硬伤——检索噪声、token 开销、模型只"照做"未真正习得（"能力在 context 不在 model"）。

核心方法：SKILL0 用 **in-context RL** 把 **skill** 内化进参数（口号"Skills at training, zero at inference"）。**ICRL**——训练 rollout 时给 skill 作 in-context 指导、推理时完全移除，让 RL 优化直接驱动"从 context 依赖到自主行为"的转变。skill 存成 Markdown (skills/{task}/{category}.md)，**context 渲染**把历史+skill 映射成紧凑 RGB 图像由视觉编码器编码 $V_t = \text{Enc}(h_t, S; c_t)$ ，policy 自生成压缩比 c_t 。**复合奖励** $\tilde{r}_t = r_t + \lambda \cdot r^{\text{comp}}_t$ ， $r^{\text{comp}}_t = \ln(c_t)$ （成功时，反映压缩边际递减）。RL 用 **GRPO**（组归一 advantage + clip + KL）。**动态课程（线性衰减预算）**： $|S^{(s)}| \leq M(s) = \lceil N \cdot (N_S - s) / (N_S - 1) \rceil$ ，逐步减到 $\emptyset$ （完全自立），保持分布偏移平滑。两阶段：Relevance-Driven Skill Grouping（离线把验证集分成 N 子任务各配一个 skill）+ Helpfulness-Driven Dynamic Curriculum（在线按 $\Delta_k = \text{Acc}^{\{\text{w/skill}\}}_k - \text{Acc}^{\{\text{w/o skill}\}}_k$ 每 d 步 Filter（留 $\Delta_k > 0$ ）/Rank/Select top-M）。helpfulness 曲线呈"先升后降"（skill 是"有效但短暂的手脚手架"）。

关键结果：3B vs AgentOCR baseline——**ALFWorld +9.7 (87.9) /Search-QA +6.6**

(40.8) /WebShop +10.1 准确率 (66.4%)；7B：ALFWorld 89.8/Search-QA 44.4/WebShop 85.1。**token <0.5k/步**（3B ALFWorld 0.38k/Search-QA 0.18k/WebShop 0.49k，比 SkillRL 的 2.21k/0.87k 低 >5 $\times$ ）。**Ablation**：预算[6,3,0]在移除 prompt 时"Fixed Full 和[6,6,6]崩 -12.3/-13.3"而 SKILL0 +1.6；"Filter&Rank&Select"是唯一正迁移 ($\Delta = +1.6\%$)，w/o Rank（随机）严重崩塌 ($\Delta = -13.7\%$)。Qwen2.5-VL 3B/7B，4 $\times$ H800，SkillBank 从 SkillRL 初始化。

意义：SKILL0 把 skill 从 inference-time 外挂转为 parameter 内化，同时解决检索噪声/token 开销/"只照做未习得"三大问题。**动态课程（逐步撤除 skill 上下文）** 是可复用的知识内化技巧。与 SkillRL 14-skillrl 形成"skill $\times$ RL"两条路（外部库共进化 vs 内化进参数）。与 SkillsBench 实证呼应（curated skill 有效 $\rightarrow$ SKILL0 把它内化）。精读见 15-skill0。GitHub github.com/ZJU-REAL/SkillZero。

2026-05 (18 命中 / 收录 4)

#26 DVAO: Dynamic Variance-adaptive Advantage Optimization for Multi-reward RL [134 $\uparrow$] — arXiv 2605.25604

问题动机：RL 已成对齐 LLM 的标准范式，GRPO 是 value-model-free 的高效 PPO 替代，但**适配到多奖励设定很难**：标准 scalarization 有两个失败模式——Reward Combination 产生"平方幅度过大的 advantage"导致不稳定，Advantage Combination "依赖静态超参且忽略跨目标相关性"。

核心方法：**DVAO** 用 rollout 组内每个目标的**经验奖励方差动态调节组合权重**——**上调学习信号强的目标、抑制噪声大的**。数学证明 DVAO 保持**有界 advantage 幅度**以稳定训练，并加**自适应跨目标正则机制**。区别于 GRPO 的静态 scalarization，方差自适应加权同时解决 Reward Combination 的幅度爆炸和 Advantage Combination 的僵化，并考虑目标间相关性。

关键结果：数学推理 + **tool-use** 基准（Qwen3/Qwen2.5），DVAO"显著超过基线方法"，达到"更优的多目标 Pareto 前沿 + 鲁棒训练稳定性"（具体数字见论文）。

意义：DVAO 把 GRPO 从单奖励推到多奖励设定，用方差自适应解决多目标 RL 的稳定性。它与 GrandCode 的三阶段 reward、HACRL 08-hacrl 的能力感知 advantage 同属"RL advantage/reward 设计精细化"，但聚焦"多奖励组合的方差自适应"。其 tool-use rollout 与 agentic RL 直接相关。本专题作为 rl_algo 简述。

#36 Self-Distilled Agentic RL (SDAR) [浙大+美团+清华, 112↑] — arXiv 2605.15155

问题动机：RL 的轨迹级奖励信号对长程多轮交互只提供粗监督。On-Policy Self-Distillation (OPSD) 在 single-turn 推理 RL 有效，但 **multi-turn agent 训练时不稳定**——学生一旦偏离 teacher 支持的轨迹，token 级监督就不可靠，per-turn KL 激增、性能灾难性退化。

核心方法：SDAR 保留 **GRPO** 为主干、把 OPSD 当门控辅助损失 $L=L_{GRPO}+\lambda\cdot L_{SDAR}$ 。诊断关键——teacher 是同一 policy 加特权上下文（检索的 skill）而非独立更强模型，**positive gap 可靠、negative gap 模糊**，且"negative-gap token 超过 50%" (Qwen2.5-3B)，朴素蒸馏有害。**Teacher-Student log-prob gap** $\Delta_t=\text{sg}(\log \pi^+_{\theta}-\log \pi_{\theta})$ 在学生采样 token 上算，**sigmoid 门** $g_t\in(0,1)$ 调制每 token (sharpness β)。三种门控：Entropy（高不确定位）/ **Gap**（默认最优，直接测 teacher 分歧，上调 **positive**、衰减 **negative**）/ Soft-OR。门用 stop-gradient detach（梯度只过学生 log-prob），证明辅助梯度有界防爆炸；用 **reverse KL** (mode-seeking，自然降权低 teacher 概率 token)。

关键结果：超 GRPO (Qwen2.5-3B)： **ALFWorld +9.4 (84.4) /Search-QA +7.0 (43.4) /WebShop-Acc +4.7 (68.0)**，7B WebShop-Acc +10.2。**稳定性：**单独 OPSD"灾难崩溃 (Search-QA 近零)"，朴素 GRPO+OPSD 在 Qwen3-1.7B"严重退化 (32.0 vs 46.1，无界蒸馏梯度)"。**技能内化：**SDAR 推理时无需 skill 却超 skill-augmented Skill-GRPO* (ALFWorld-1.7B 53.9 vs 28.1)。**Random-Retrieval 发现：**零任务感知的随机检索也超 GRPO (+1.9/+1.6/+1.0)，证明增益来自门控蒸馏而非检索保真。**Ablation：** $\beta=5$ 、 $\lambda=0.01$ 最优，Gap gating 胜 entropy/soft-OR，reverse KL 胜 forward/JSD。

意义：SDAR 把 GRPO 系列从 single-turn 推到 multi-turn agent 训练的标准方案——sigmoid 门控的非对称信任 (positive 强化、negative 软抑制)。与 GrandCode 的 Agentic GRPO、DeITA 并列 2026 H1 RLVR for agent 三巨头。详见 [huggingface/08-sdar.md](https://huggingface.com/08-sdar.md)，本专题作为 rl_algo 交叉引用。GitHub github.com/ZJU-REAL/SDAR。

#37 Skill1: Unified Evolution of Skill-Augmented Agents via RL [112↑] — arXiv 2605.06130

问题动机：持久 skill 库让 agent 跨任务复用成功策略，但维护这种库需要三个耦合能力——**选择相关 skill**、**执行时利用 skill**、从经验**蒸馏**新 skill。如何用 一个 RL 框架统一这三者？

核心方法： Skill1 用单一 **policy** 同时进化 **skill selection / utilization / distillation** 三个能力。流程：agent 生成查询搜 skill 库 → skill 重排选最相关 → 条件求解（用 skill 解任务）→ 成功后蒸馏新技能加入库。低频任务归功于 selection（找对 skill 就赢），高频任务归功于 distillation（创造新 skill 解锁更广任务）——把整个 skill lifecycle 用一个 reward 信号统一驱动。

关键结果： ALFWorld + WebShop 上超过先前 skill 工作（具体数字见论文）。

意义： Skill1 避免"skill selector/executor/extractor 各训各的"碎片化，把 skill lifecycle 用一个 reward 统一。与 SkillRL 14-skillrl（递归进化）、SKILL0 15-skill0（内化）、SkillClaw（生态级）、SkillOpt（text-space SGD）构成完整 skill × RL 谱系。详见 [huggingface/00 W19](#)，本专题作为 skill 交叉引用。

#44 OpenSearch-VL: Open Recipe for Multimodal Search Agents [腾讯混元, 102↑] — arXiv 2605.05185

问题动机： top-tier 多模态搜索 agent 仍难复现——缺乏完全开源的训练 recipe（数据 + 算法 + 权重）。

核心方法： 完全开源的 frontier 多模态 deep search agent recipe（agentic RL）。**数据 pipeline：** Wikipedia path sampling（知识图谱路径生成多跳问题）+ fuzzy entity rewriting（模糊实体改写降低表面匹配作弊）+ source-anchor visual grounding（减少 shortcut）→ SearchVL-SFT-36k + SearchVL-RL-8k。**工具环境：** 统一 text/image search + OCR + cropping/sharpening/super-resolution/perspective correction。**算法——multi-turn fatal-aware GRPO：** mask 失败后 token（避免错误污染后续）+ one-sided advantage clamping（保留失败前有用推理）。

关键结果： 7 个多模态搜索基准平均 **+10pt+**，多任务匹敌商用模型。GitHub github.com/shawn0728/OpenSearch-VL (215★)。

意义： OpenSearch-VL 把"开源多模态 DR"整套 pipeline（数据/算法/权重）公开。其 fatal-aware GRPO（失败后 token 掩码 + 单侧 advantage 钳制）是多轮 agentic RL 的实用技巧。详见 [huggingface/00 W19](#) 与 [deep-research/08](#)，本专题作为 deep_research RL 交叉引用。

#22 AgentDoG 1.5: Alignment Framework for AI Agent Safety [上海AI Lab, 142↑] — arXiv 2605.29801

问题动机： OpenClaw 等开放世界 agent 有强大跨环境执行力，却引入广泛新安全风险源；前沿 AI 大幅降低攻击门槛，使现有 agent 对齐框架不足以真实部署。

核心方法： 轻量、可扩展的 **agent 安全对齐框架**。① 更新 agent 安全 **taxonomy** 以容纳 Codex/OpenClaw 执行场景的新兴风险；② **taxonomy** 引导的数据引擎 + **influence-function** 净化，仅用约 **1k** 样本训出 AgentDoG 1.5（0.8B/2B/4B/8B），达到与 GPT-5.4 等闭源相当的性能；③ 构建高

效 **agentic 安全 SFT + RL 训练环境**，把 Docker 级部署开销降低**两个数量级 (~100x)**；④ 部署为 **training-free 在线护栏**做实时安全审核。

关键结果：与领先闭源（GPT-5.4）相当，Docker 部署开销 **-100x**，在多样复杂交互 agentic 场景达 SOTA。模型/数据全开源。50 作者（Dongrui Liu 等），44 页。

意义：AgentDoG 1.5 把 agent 安全对齐做成轻量、可扩展、含 RL 训练环境的框架，应对开放世界 agent（OpenClaw/Codex）的新兴安全风险。它是本专题唯一的 `safety_eval` 类工作，与 `huggingface/` 的 AgentDoG/ClawKeeper 安全工作一脉，其"agentic 安全 SFT+RL 训练环境"把 RL 引入安全对齐。本专题作为 `safety_eval` 简述。

2026-06（13 命中 / 收录 6）

★ #45 Harness-1: RL for Search Agents with State-Externalizing Harnesses [UIUC / Chroma, 52↑] — arXiv 2606.02373

问题动机：搜索 agent 通常被训成"在不断增长的 transcript 上的 policy"——模型既要决定"怎么搜"，又要记住"看过什么、哪些证据有用、哪些约束未满足、哪些 claim 已核实"。这是把**太多例行状态管理塞进 policy**，逼 RL 同时学"语义搜索决策"和"可恢复的记账"，样本效率低、泛化差。

核心方法：Harness-1 是 **20B 检索 subagent**，在 **stateful search harness** 内用 RL 训练。harness 在环境侧维护 working memory：**candidate pool**、**importance-tagged curated set**、**compact evidence links**、**verification records**（哪些 claim 已核查）、**压缩去重的 observations**、**budget-aware context rendering**（按 token 预算决定给 policy 看什么）。policy 只保留真正需要智能的**语义决策**：搜什么、留/弃哪些文档、验证什么、何时停。核心论点——RL 否则被迫同时优化"语义检索决策"和"可恢复的记账"，把后者外置让 RL 集中火力在前者。作者 Jiawei Han 组（UIUC）+ Chroma（向量数据库公司）。

关键结果：8 个检索基准（web/finance/patents/multi-hop QA）平均 curated recall **0.730**，比次优开源 subagent **+11.4pt**；在 **held-out transfer**（未见过的迁移基准）上增益尤强——说明"语义决策"比"记账"更可迁移（记账是任务特定的，语义能力通用）。GitHub 548★。

意义：Harness-1 给出可操作的设计原则——把"可恢复的状态"外置给环境，只让 RL 优化"不可恢复的**语义决策**"，对所有长程 agent（不只搜索）有借鉴意义，是"harness engineering"（系统级设计与权重训练同等重要）的精确实证。与 LLM-in-Sandbox [04-llm-in-sandbox](#) 形成"环境职责切分"两极（做薄 vs 做厚），与 IterResearch [11-iterresearch](#)"policy 周期性重建"是长程状态管理的两条路。精读见 [13-harness-1](#)，亦是 `memory/01-harness-1`、`deep-research/09` 核心。GitHub github.com/pat-jj/harness-1。

#12 GrepSeek: Training Search Agents for Direct Corpus Interaction [UMass, 106↑] — arXiv 2605.29307

问题动机：传统 retriever 把语料压缩成"固定 top-k 相似度接口"，对 agentic search 是瓶颈——精确词约束、稀疏线索合取、被早期滤掉的证据都无法被下游推理找回。如何用 RL 训练 agent 直接用 shell 与语料交互？

核心方法：GrepSeek 让 search agent 把语料本身当搜索环境，用可执行 shell 命令

(grep/find/sed/awk) 找证据。**两阶段训练：**① cold-start 数据集——用 **answer-aware Tutor** (知答案的导师解释 shell 用法) + **answer-blind Planner** (不知答案的规划器拆解检索意图) 生成 verified、因果 grounded 的轨迹；② **GRPO** refine policy (reward = 找到正确答案 + 用了多少 shell 命令)。**工程：****semantics-preserving sharded-parallel execution engine**——把 shell 检索加速**最多 7.6x**且 byte-exact 等价于顺序执行。

关键结果：7 个开放域 QA 基准 token-level F1 与 EM 最强；指出纯 lexical 交互在 surface-form 变化大的 query 上的局限。GitHub 42★。

意义：GrepSeek 把 DCI (Direct Corpus Interaction) 从论点变成可训练、可部署的系统，预示 retrieval 范式从"embed + ANN"转向"agent + shell"。详见 deep-research/10，本专题作为 deep_research RL 交叉引用——其 GRPO + shell 检索是"agent 用工具直接交互 + RL 训练"的代表。

#20 Role-Agent: Bootstrapping LLM Agents via Dual-Role Evolution [AMAP, 73↑] — arXiv 2606.10917

问题动机：LLM agent 的学习常受限于**低效交互反馈 + 静态训练环境**，阻碍泛化。能否让一个 LLM 同时当 agent 和环境、自举共进化？

核心方法：Role-Agent 用**单一 LLM 同时充当 agent 和 environment**，实现自举共进化。两个协同组件：① **World-In-Agent (WIA)**——LLM 当 agent，每个动作后**预测未来状态**，预测与实际状态的对齐度作为 **process reward**，鼓励"环境感知推理"（给出密集的逐步反馈而非稀疏的任务末信号）；② **Agent-In-World (AIW)**——LLM 分析失败轨迹的失败模式、检索相似失败模式的任务，重塑训练数据分布做针对性练习（解决静态训练环境问题）。

关键结果：多个基准上一致提升，平均比强基线 +4%。

意义：Role-Agent 用"单 LLM 双角色"（WIA 给 process reward + AIW 重塑数据分布）解决"低效反馈 + 静态环境"两个限制。它与 Agent0 [05-agent0](#)（出题者-解题者）、Role 的"预测未来状态作 process reward"与 DreamGym [01-dreamgym](#)（经验模型预测状态转移）思路相通，是"agent 自举共进化"的代表。本专题作为 agent_train 简述。GitHub github.com/AMAP-ML/roleagent。

#28 Masking Stale Observations Helps Search Agents — Until It Doesn't [McAuley Lab, 62↑] — arXiv 2606.00408

问题动机：长程 search agent 跨多次 tool call 积累大量检索内容，context 预算效率重要。最小干预是 mask 掉过期观察，但何时有用、为何有用不清楚。

核心方法：系统实验——扫 4B–284B backbone × 3 retriever × 离线/实时 web 基准。**核心发现：**masking 的准确率增益（相对"无 context 管理"）呈**非对称倒 U 形 regime**——弱 retriever 下平台、强 retriever 配中等模型时峰值、模型饱和时骤降。**机制：**masking 是 **token-for-turn 权衡**（移除模型已不 attend 的观测换更多 turn），增益取决于 retriever recall 与模型 implicit filtering capacity 的交互。把 context 管理重定义为 **regime-dependent**。

关键结果：把 context 管理重新定义为 regime-dependent 干预——没有银弹。GitHub 16★。

意义：这篇是对所有"激进 context 压缩"工作的重要反思——证明 context 管理策略必须匹配 (retriever recall × model filtering capacity) 的具体 regime。它与 RL 的关联在于：长程 search agent RL 的上下文管理（如 Harness-1 [13-harness-1](#) 的 budget-aware rendering）需要这种 regime 意识。本专题作为 deep_research（上下文管理）简述，亦是 memory/02-masking、deep-research/09 核心。

#40 DRIFT: Span-Level Error Localization in Agent Trajectories [NJU, 54↑] — arXiv 2606.02060

问题动机：基于最终答案的评测只能看"成没成功"，看不出"轨迹哪部分让答案不可靠"——DR agent 的长轨迹到底是哪一步开始错的？这对 RL 奖励设计有直接启示（密集的过程级信号比稀疏的最终奖励更有用）。

核心方法：收集 2 个 agent 框架 × 3 backbone × 3 基准的 **2,790 条真实轨迹**，转成 semantic span，LLM-assisted 专家标注 harmful error span，建 **TELBench (1000 实例)**。提出 **DRIFT——claim-centric 审计框架**：追踪 agent 的 claim、核查其在轨迹证据中的支撑、标记影响答案路径的 unsupported/conflicting span。

关键结果：DRIFT 把 span-level error localization 与 first-error accuracy 提升**最多 30pp**，提供 DR agent 可靠性的 process-level 视角。GitHub 21★。

意义：DRIFT 把 DR 评测从"最终答案对错"推进到"span 级错误定位"，回答"哪一步开始错"。它对 agentic RL 的价值在于——**过程级错误定位可转化为更密的 RL 奖励信号**（呼应 OpenClaw-RL [03-openclaw-rl/CUDA Agent 07-cuda-agent](#) 的 process reward）。本专题作为 deep_research（评测/过程奖励）简述，亦是 deep-research/13 核心。

#48 SearchSwarm: Delegation Intelligence in Agentic LLMs [49↑] — arXiv 2606.09730

问题动机：长程 deep research 的上下文需求可无界增长，但模型上下文窗口有限。如何让 agent 通过"委派"分摊上下文压力？

核心方法：核心能力是 **delegation intelligence**（委派智能）——main agent 分解任务、决定何时委派什么给 subagent、整合 subagent 返回的摘要结果，以节省主上下文预算。设计 **harness** 引导模型做高质量任务分解与委派，并约束 subagent 正确返回结果；harness 引导的轨迹天然编码正确委派决策，用作 SFT 数据把 delegation intelligence 内化进权重。

关键结果：SearchSwarm-30B-A3B 在 **BrowseComp 68.1 / BrowseComp-ZH 73.3**，同级最佳。GitHub 63★。

意义：SearchSwarm 把"何时委派什么给 subagent"作为可训练能力（delegation intelligence），是 DR scaling 第三轴"委派"的代表。它与 WideSeek-R1 10-wideseek-r1（宽度并行）是 multi-agent 组织的两种形态（委派 vs 并行），与 MiroThinker（交互深度）共同构成 DR scaling 三个新轴。本专题作为 multi_agent 简述，亦是 deep-research/12 核心。GitHub github.com/Search-Swarm/SearchSwarm。

三、研究现状与趋势（2025 H2 → 2026 H1）

1 Rollout 成本是 Agentic RL 的第一性约束，"经验合成"成为主流解法

真实环境 rollout 慢、贵、奖励噪声大、基建复杂，是 agent RL 落地的最大障碍。2025 H2 起出现一批"绕过真实 rollout"的工作：

- **DreamGym** (01-dreamgym) 把环境动态蒸馏成 reasoning-based experience model，纯合成交互媲美 GRPO/PPO；
- **EvoCUA** (06-evocua) / **Agent-World** 走另一条路——自动合成可验证环境 + 数万异步 sandbox 并行把真实 rollout 规模化；
- 共同点：**environment/experience-as-data**，把"造数据"和"训 policy"合成一个自维持循环。

2 从"标量奖励"到"信号丰富化"——next-state / 反思 / rubric

标量奖励对长程多轮 agent 太稀疏。三条丰富化路线：

- **next-state signal** ([OpenClaw-RL 03-openclaw-rl](#)) ——用户回复 / 工具输出 / 状态变化里既有 evaluative 又有 directive 信号，后者经 hindsight OPD 抽成 token 级方向监督；
- **反思 consolidation** ([ERL 02-experiential-rl](#)) ——把"反思→改进→内化"显式嵌入 RL loop；
- **演化 rubric** ([DR Tulu 12-dr-tulu](#)) ——长答案不可验证时，让 rubric 与 policy 共进化提供判别性反馈。

3 多轮信用分配 = 2026 H1 RLVR 算法进步的共同语言

GRPO 在 single-turn 推理有效，但 multi-turn agent 轨迹里"部分 turn 对、部分错"会让朴素信用分配信号互相抵消：

- **GrandCode 的 Agentic GRPO** ([🔗](#)) ——两阶段更新 (immediate + delayed correction) 解决 multi-stage rollout off-policy 漂移；
- **SDAR** ([🔗](#)) ——sigmoid 门控非对称信任；
- **HACRL/HACPO** ([08-hacrl](#)) ——异构 agent 间无偏 advantage 共享；
- 都在用 **token/turn 级统计指标**定位并修正信用分配偏差。

4 Multi-Agent RL 的三种新解法：异构互学 / 测试时 / 宽度扩展

MARL 训练贵且不稳定 (非平稳 + 高方差)，2026 H1 出现三种绕法：

- **异构互学** ([HACRL 08-hacrl](#)) ——训练时共享 rollout、推理时独立，避免协同部署；
- **测试时** ([MATTRL 09-mattrl](#)) ——不更新权重，只在推理时注入结构化文本经验做多 agent 审议；
- **宽度扩展** ([WideSeek-R1 10-wideseek-r1](#)) ——lead-subagent MARL 把"广度信息检索"并行化，4B 媲美 671B 单 agent。

5 Skill 从"inference-time 检索"走向"RL 内化"

Skill 作为 frozen-model 时代的能力载体，2026 H1 的关键转向是把 **skill 训进权重**：

- **SkillRL** ([14-skillrl](#)) ——experience distillation 建 SkillBank + 递归进化与 policy 共进；
- **SKILL0** ([15-skill0](#)) ——in-context RL 内化 skill，训练时逐步撤除 skill 上下文直到 zero-shot，消除检索噪声与 token 开销；
- 与 huggingface/ 库的 Skill1 / SkillClaw / SkillOpt 一道，构成"skill × RL"完整谱系。

6 "环境/Harness 设计"与"权重训练"同等重要

- **LLM-in-Sandbox** ([04-llm-in-sandbox](#)) ——极简 code sandbox + 非 agentic 数据 RL 就能激发通用 agent，质疑"复杂 harness"假设；

- **Harness-1** ([13-harness-1](#)) ——反过来把状态管理外置到 **harness**，让 RL 只优化语义决策；
- **IterResearch** ([11-iterresearch](#)) ——周期性重建 workspace 解决 mono-context 膨胀；
- 三者共识：**RL** 该优化什么、不该优化什么，取决于环境/**harness** 怎么切分职责。

7 Agentic RL 已在"最专家化领域"超越 frontier 闭源

- **CUDA Agent** ([07-cuda-agent](#)) 在 GPU kernel 生成上 KernelBench L3 比 Claude Opus 4.5 / Gemini 3 Pro 高 ~40%；
- **GrandCode** ([🔗](#)) 在 Codeforces 直播击败所有人类；
- 证明 agentic RL 不只是"追平"，在**有可靠自动验证器**的领域已能**反超**最强闭源模型。

8 自演化 / 零数据 是 agent 摆脱"人类数据天花板"的方向

- **Agent0** ([05-agent0](#)) 零外部数据、双 agent 共进化；
- **MetaClaw / Role-Agent** 部署中持续演化；
- 与 huggingface/ 的 SkillClaw (生态级)、evolve/ 专题一道，指向"agent 自己造课程、自己出题、自己进化"的范式。

四、收录清单速查（39 篇）

#	论文	月/票	类	精读
01	DreamGym	2025-11 / 83↑	A	★
02	Experiential RL (ERL)	2026-02 / 75↑	A	★
03	OpenClaw-RL	2026-03 / 156↑	A	★
04	LLM-in-Sandbox	2026-01 / 87↑	A	★
05	Agent0	2025-11 / 110↑	B	★
06	EvoCUA	2026-01 / 92↑	B	★

#	论文	月/票	类	精读
07	CUDA Agent	2026-03 / 99↑	B	★
08	HACRL	2026-03 / 198↑	C	★
09	MATTRL	2026-01 / 92↑	C	★
10	WideSeek-R1	2026-02 / 100↑	C	★
11	IterResearch	2025-11 / 80↑	D	★
12	DR Tulu	2025-11 / 63↑	D	★
13	Harness-1	2026-06 / 52↑	D	★
14	SkillIRL	2026-02 / 76↑	E	★
15	SKILL0	2026-04 / 101↑	E	★
	MEDS · DVAO	04/05	A	简述
	MetaClaw · Agent-World · GroundCUA · GeoVista · Role-Agent · OpenGame · Thinking-with-Map · SWE-rebench-V2	—	B	简述
	SearchSwarm	2026-06	C	简述
	OpenSearch-VL · GrepSeek · Observation-Masking · DRIFT · MiroThinker	—	D	简述/ 
	Skill1	2026-05	E	
	GLM-5 · Kimi K2.5 · Youtu-Agent · LongCat · GrandCode · SDAR · Let-It-Flow	—	F	简述/ 
	AgentDoG 1.5	2026-05	G	简述

🔗 交叉引用 [huggingface/](#) 周榜库已有精读: GrandCode→01 | SDAR→08 | GLM-5→06 | Kimi K2.5→13 | Youtu-Agent→05 | MiroThinker→12 | OpenSearch-VL/GrepSeek/Skill1/Let-It-Flow→
见 [huggingface/00-summary](#) 。