

HuggingFace 月榜 Agent Evolve 论文汇总

(2025-11 ~ 2026-06)

数据范围：HuggingFace Papers 月榜 2025-11 至 2026-06（共 8 个月），每月 **top 100**

筛选主题：**Agent Evolve / 自演化 Agent**——自演化训练、skill 进化、演化式优化、环境/课程协同进化、记忆进化、组织级/元自改进、多模态/GUI 自演化

共收录：**50 篇**（深读 14 📖 + 简述 34 📄 + 跨库引用 2 🔗）

标记：📖 = 本库精读笔记 | 📄 = 月榜简述 | 🔗 = 已在 [huggingface/](#) 目录精读

📖 50 篇按主题分类

分类	篇数	主题一句话
① 自演化 Agent 训练框架	8	agent 不靠人工数据，靠自造课程/经验/环境持续变强
② Skill 进化	13	把经验蒸馏为可复用 skill，让 skill 库与 policy 共进化、并治理整个生态
③ 演化式优化 / 搜索 (LLM × Evolution)	6	把遗传算法的变异/交叉搬到 LLM，做受控演化搜索
④ 环境 / 课程协同进化	5	让环境/任务也跟着 agent 一起进化
⑤ 记忆进化	6	把经验/环境演化编码进可学习、可进化的记忆
⑥ 组织级 / 元 (meta) 自改进	5	从单 agent 进化扩展到 agent 组织、agent 设计 agent、自指元进化
⑦ 多模态 / GUI 自演化	5	把自演化范式推广到 VLM、空间智能、GUI agent
⑧ 综述	2	agent 视角（能力分层）+ 环境视角（生命周期）

📖 14 篇精读（原 top-50 核心）：01-09、13、14、18、21、22（编号见各 md 文件）

📄 34 篇简述在下方"按月列出"中给出要点

一、按月列出（每篇 800–1000 字详述，基于 arXiv 原文）

每篇展开为 800–1000 字，基于论文正文撰写，覆盖问题动机 / 核心方法（含机制细节） / 关键结果（含具体数字） / 意义与定位。📖 = 本库精读，📄 = 月榜简述（已扩写），🔗 = 已在 huggingface/ 精读、此处交叉引用。条目末标注〔分类①~⑧〕对应开头分类表。

2025-11（6 篇）

#14 GigaEvo: An Open Source Optimization Framework Powered By LLMs And Evolution Algorithms 📄 [AIRI, 121↑] — arXiv 2511.17592 → 见 [15-gigaevo](#)〔分类③〕

问题动机：Google 的 AlphaEvolve 展示了"LLM + 进化算法"在数学/算法优化上的强大威力，但其已发表的描述是高层次的、留下大量实现细节未明，阻碍了社区的可复现性与后续研究。开源社区缺一个把 AlphaEvolve 关键组件完整、模块化实现的基建。

核心方法：GigaEvo（AIRI 出品）是一个开源的 LLM-进化混合优化系统，把 AlphaEvolve 的关键组件全部模块化开源：① **MAP-Elites 质量-多样性算法**——维护一个按行为特征划分的精英解网格，兼顾质量与多样性，避免过早收敛；② **异步 DAG 评估流水线**——把候选解的评估组织成有向无环图并行执行，提升吞吐；③ **LLM 驱动的变异算子**——带 **insight 生成**（让 LLM 解释为何这样变异）+ **双向 lineage 追踪**（记录每个解的祖先/后代谱系）；④ **灵活的 multi-island 演化策略**——多个独立演化"岛屿"并行、定期迁移。系统强调"模块化、并发、易实验"，支持声明式配置快速原型。

关键结果：在 AlphaEvolve 论文的三个挑战问题上复现验证实现正确性——**Heilbronn 三角放置**、**圆填充 (circle packing)**、**高维 kissing number**。代码托管在 AIRI-Institute/gigaevo-core。8 位作者（Valentin Khrulkov、Ivan Oseledets 等）。

意义：GigaEvo 为"LLM × 进化算法"社区提供了可复现的基础设施——把 AlphaEvolve 这一里程碑工作从"知道它很强但复现不了"变成"开源可用、可改、可扩展"。它是本库演化式优化派（与 [13-cse](#) CSE、[14-quantaalpha](#) QuantaAlpha、BES、TTT-Discover 等）的工程基座，让后续研究者不必从零重建 MAP-Elites + 异步评估 + LLM 变异这套复杂机制。在"进化的单位上移"趋势里，它守住了最底层的"算法/代码进化"这一原始战场。

#17 Agent0: Unleashing Self-Evolving Agents from Zero Data via Tool-Integrated Reasoning 📖 [UNC, 110↑] — arXiv 2511.16043 → 精读 [01-agent0](#)〔分类①〕

问题动机：LLM agent 用 RL 训练时严重依赖人类策划的数据——既限制规模，也把 AI 能力上限拴死在人类知识上。已有自演化框架的两大短板：受限于模型自身能力（自己出的题不会超过自己太多）、且多为单轮交互，难构造涉及工具使用/动态推理的复杂课程。

核心方法：Agent0 从同一个 base LLM (Qwen3-Base) 初始化两个 agent——**Curriculum Agent π_θ (出题者)**与 **Executor Agent π_ϕ (解题者)**——做 T=3 轮共生竞争 (symbiotic competition)。每轮两阶段：① 用 GRPO 训 π_θ 生成挑战冻结的 executor 的任务；② 冻结 π_θ 、生成任务池、过滤出数据集，再用 **ADPO** (Ambiguity-Dynamic Policy Optimization) 训 π_ϕ 。**任务过滤**靠 self-consistency $\hat{p}(x)$ ：保留 $|\hat{p}-0.5|\leq\delta=0.25$ (即 $\hat{p}\in[0.3,0.8]$ 的"不太易也不太难"任务)。**Curriculum reward** 三信号：Uncertainty + Tool Use (鼓励工具调用, cap=4) + Repetition Penalty。**工具集成推理**用"stop-and-go"多轮 rollout (生成→暂停→沙箱执行→结果回传→继续到 \boxed{ })。**工具是打破能力天花板的关键**——让 co-evolution 不早熟 (出题者必须构造工具感知的更难任务)。ADPO 用 Ambiguity-Aware Advantage Scaling (降权噪声伪标签) + Ambiguity-Modulated Trust Regions (对模糊任务放松 clip)。

关键结果：Qwen3-8B-Base 上**数学推理 +18%、通用推理 +24%**，全程零外部数据。数学 AVG 49.2→58.2 (超 R-Zero 6.4%、Socratic-Zero 3.7%)。**共进化进程证据：**固定 executor pass rate 逐轮 64.0→58.5→51.0 下降、平均 tool call 1.65→2.10→2.60 上升。1.2k★。

意义：Agent0 是**零数据自演化奠基作**——证明 agent 可"自己造课程、自己出题、自己进化"，摆脱人类数据天花板。出题者-解题者对抗是 self-play 的课程版，工具集成是不早熟的关键。它与同组 (aiming-lab) 的 [05-skillrl](#) SkillRL、MetaClaw、Agent0-VL 一脉，是本库"co-evolution + zero-data"主线的源头，也是 agentic-rl 专题 [agentic-rl/05-agent0](#) 的同一工作。精读见 [01-agent0](#)。

#29 AutoEnv: Automated Environments for Measuring Cross-Environment Agent Learning [FoundationAgents, 92↑] — arXiv 2511.19304 → 见 [16-autoenv](#) [分类④]

问题动机：人类能在动态各异的世界间适应，但现有 agent 多在**单一域内**自演化，隐含"环境分布固定"的假设；**跨环境学习 (cross-environment learning)** 几乎无人测——我们根本不知道 agent 学到的能力能否迁移到动态不同的新环境。

核心方法：AutoEnv 把环境当作***"转移/观察/奖励的可因子化分布 (factorizable distribution)"——这种分解让框架能独立改变每个因子、自动生成异构世界，平均仅 \$4.12** 低成本生成一个环境。基于此构建 **AutoEnv-36** (36 个环境、358 个验证关卡)。把 agent 学习形式化为**组件中心 (component-centric)** 的过程，由 **Selection** (选择改进哪个组件) - **Optimization** (优化) - **Evaluation** (评估) 三阶段驱动，据此设计 **8 种学习方法**。

关键结果：跨 **7 个 LM**，归一化奖励仅 **12–49%**——跨环境学习是真实挑战。关键发现：**任何单一学习方法的增益随环境数增多而快速衰减** (固定方法不跨异构世界 scale)；**环境自适应地选择学习方法能大幅提升**，但随方法空间扩大呈现边际递减。代码 github.com/FoundationAgents/AutoEnv。15 作者。

意义：AutoEnv 把"跨环境学习"这一被忽视的盲区建成可量化的测试床——它揭示了**现有自演化方法在单域内有效、但跨异构环境几乎不 work** (7 个 LM 仅 12-49%)。这直接定义了本库"终身、跨域演

化"未来方向的起点（见趋势 方向¹）。它把"环境"从背景提升为一等公民，与 [03-agent-world](#)（环境自合成）、[18-evoarena](#)（环境演化评测）、[22-agentic-env-survey](#)（环境工程综述）共同构成"环境驱动能力进化"主线。

#33 Scaling Agent Learning via Experience Synthesis (DreamGym) 📖 [Meta, 83↑] — arXiv 2511.03773 → 精读 [04-dreamgym](#) [分类①]

问题动机：RL 能通过交互增强 LLM agent，但实际落地受阻于昂贵的 rollout、有限的任务多样性、不可靠的奖励信号、复杂的基建——这些都阻碍可扩展经验数据的收集。

核心方法：DreamGym 是首个为可扩展性设计、用合成经验做 **online agent RL** 的统一框架。核心是把环境动态蒸馏成一个 **reasoning-based experience model**（基于推理的经验模型）——给定 (state, action)，模型通过 step-by-step 推理产生一致的状态转移与反馈信号，替代昂贵的真实 rollout（用语言推理刻画状态转移逻辑，一次 LLM 前向代替一次容器执行）。三件套：reasoning-based experience model + **experience replay buffer**（用真实数据初始化、持续补充新交互）+ **自适应任务生成**（在线课程，生成挑战当前 policy 的新任务）。对照 RL 算法用 GRPO 与 PPO，核心卖点是"用什么数据喂 RL"。

关键结果：WebArena 非 RL-ready 设定超所有基线 **30%+**；RL-ready 但 rollout 昂贵的设定下纯合成交互即媲美 **GRPO/PPO**；**sim-to-real warm-start** 用远少于真实交互量获得显著额外增益。作者含 Jason Weston、Dawn Song、Bo Li。

意义：DreamGym 把 agent RL 的成本从"维护真实环境集群"降到"训练 + 调用经验模型"，确立 world-model-for-RL 在 LLM agent 语境下的可行性（用推理而非像素生成）。它的"reasoning-based experience model"本质是轻量 world model，是本库"经验合成 / 自造数据"主线的源头（与 [03-agent-world](#) 合成环境、[02-evocua](#) 合成 CUA 经验呼应），也是 agentic-rl 专题 [agentic-rl/01-dreamgym](#) 的同一工作。精读见 [04-dreamgym](#)。

#69 Agent0-VL: Exploring Self-Evolving Agent for Tool-Integrated Vision-Language Reasoning 📖 [UNC, 49↑] — arXiv 2511.19900 [分类⑦]

问题动机：视觉-语言 agent 的学习受限于人类标注监督。已有 self-rewarding 方法让模型当自己的 critic，但纯文本的 **self-evaluation** 无法验证复杂的视觉推理步骤、且常产生评估幻觉——模型"看错了还以为自己对"。

核心方法：Agent0-VL（[01-agent0](#) 的视觉版）的关键创新是把工具集成不只用于推理，还用于 **self-evaluation** 与 **self-repair**。它在单个 LVLM 里统一两个角色：**Solver**（做多轮工具集成推理）+ **Verifier**（通过 tool-grounded critique 产生结构化反馈 + 细粒度 self-reward）。缓解视觉自评幻觉的办法是——把验证 grounding 在工具证据上而非纯文本内省（让 agent 用工具实际核验自己的视觉推理结论，而非凭感觉自判）。两角色通过 **Self-Evolving Reasoning Cycle** 交互，tool-based verification 与

RL 联合对齐推理与评估分布，实现"zero-external-reward evolution"（无需人工标注或外部奖励模型）。

关键结果：在几何问题求解 + 视觉科学分析上评测，比 **base model +12.5%**。代码 github.com/aiming-lab/Agent0。

意义：Agent0-VL 把自演化推进到 VLM，针对性地解决了"视觉自评幻觉"这一多模态特有难题——**用工具证据 grounding 自我验证**，让 self-evolution × tool-integrated × multimodal 三者交叉可行。它是本库"自演化向多模态扩散"主线（与 VisPlay、MM-Zero、UniCorn、SpatialEvo）的早期代表，证明 **01-agent0** 的零数据自演化范式可移植到视觉模态、且工具集成是缓解视觉幻觉的钥匙。57★。

#75 VisPlay: Self-Evolving Vision-Language Models from Images [WashU/Maryland, 45↑] — arXiv 2511.15661 [分类⑦]

问题动机：RL 是改进 VLM 复杂推理的有原则框架，但现有方法依赖人工标签或任务专属 heuristics 来定义可验证奖励——**成本高、难 scale**。能否从海量无标注图像自演化 VLM？

核心方法：VisPlay 是从无标注图像自演化的 **RL 框架**。从单个 base VLM 出发，切成两个交互角色：**Image-Conditioned Questioner**（出"有挑战但可答"的视觉问题）+ **Multimodal Reasoner**（产 silver 答案）。两角色用 **GRPO 联合训练**，GRPO 整合 **diversity 奖励**（问题多样性）和 **difficulty 奖励**（问题难度），平衡"生成问题的复杂度"与"silver 答案的质量"。关键是**操作在无标注图像数据上**，移除了对人工标注标签的依赖。

关键结果：在 Qwen2.5-VL 和 MiMo-VL 两个模型族、8 个基准（含 MM-Vet、MMMU）上评测，在视觉推理、组合泛化、幻觉减少上均有提升。项目页公开。57★。

意义：VisPlay 把 **01-agent0** 式双角色自博弈落地到视觉模态，规模化利用海量无标注图像——证明 VLM 也能像 LLM 一样"从无标注数据自演化"。它与 Agent0-VL（工具增强自评）、MM-Zero（三角色零数据）、UniCorn（理解→生成）共同把自演化范式推广到多模态，各自解决模态特有难题（VisPlay 解决"如何从无标注图像定义可验证奖励"）。

2025-12 (2 篇)

12 月 top-50 中无明确以"agent 自演化"为核心的论文，但 **top-100 中出现 2 篇**（其余命中多为模型技术报告、扩散语言模型、deep research，已归入其它目录）。

#58 Guided Self-Evolving LLMs with Minimal Human Supervision (R-Few) [腾讯, 55↑] — arXiv 2512.02472 [分类①]

问题动机：自演化被设想为通往超级智能的路径，但**无引导的自演化系统常快速 plateau 甚至退化**。根因是三个失败模式——模型"强化自身偏见、收敛到低熵行为"：**concept drift**（迭代中逐渐失去与任务

概念的对齐)、**diversity collapse** (输出多样性萎缩)、**mis-evolution** (强化内部偏见而非纠正)。

核心方法: **R-Few** 是 **guided Self-Play Challenger-Solver** 框架。每轮: **Challenger** 采样一小组人类标注样本来引导合成问题生成; **Solver** 在"在线、难度递进的课程"下联合训练人类样本 + 合成样本。两个关键技术: ① **in-context grounding**——通过标注样本注入轻量人类监督来引导生成; ② **mixed training**——混合人类与合成数据稳定 co-evolution。即用极少量人类监督把自演化稳定可控。

关键结果: Qwen3-8B-Base 上比 R-Zero **+3.0 分** (数学); 与 General-Reasoner 持平, 而后者用了 **20× 更多人类数据**。Ablation 证实 grounded challenger 训练与课程化 solver 训练的互补贡献, R-Few 缓解 drift、产生更稳定可控的共进化动态。作者含 Haitao Mi、Dong Yu (腾讯)。

意义: R-Few 是自演化稳定性问题的代表性诊断 + 解法——它明确命名了无引导自演化的三种塌缩模式 (concept drift / diversity collapse / mis-evolution), 并用"极少人类监督 + 课程 + 混合训练"稳住。这是本库"防对抗崩溃/防塌缩"主线 (与 08-ctx2skill Cross-time Replay、OpenSkill/SCOPE 开放世界 bootstrap) 的关键一环, 直接对应趋势方向¹⁰ "开放世界 bootstrap + 防塌缩"。它证明: 完全无引导的自演化会退化, 少量 grounding 就能换来巨大稳定性 (vs 20× 数据的强基线)。

#96 Reinforcement Learning for Self-Improving Agent with Skill Library (SAGE) 📄 [42↑] — arXiv 2512.17102 [分类②]

问题动机: LLM agent 虽在复杂推理与多轮交互上能力强, 但部署到新环境时难以持续改进与适应。现有 skill library 方法多靠 **LLM prompting**, 实现不稳定 (一致性差) ——用 RL 系统性地把 skill 纳入学习是更可靠的路线。

核心方法: **SAGE (Skill Augmented GRPO for self-Evolution)** 把 skill 系统性融入 GRPO 学习, 两个关键机制: ① **Sequential Rollout**——每次 rollout 让 agent 在一连串相似任务上迭代部署, 早期任务产生的 skill 累积进库、供后续任务使用 (边解边攒 skill); ② **Skill-integrated Reward**——一个补充原始 outcome-based 奖励的信号, 同时强化 skill 生成与 skill 利用。两者驱动 GRPO 更新。

关键结果: 在 **AppWorld** 上, SAGE 应用到带专家经验 SFT 的模型时——**Scenario Goal Completion** 高 8.9%、交互步数少 26%、生成 token 少 59%, 在准确率与效率上都大幅超过现有方法。

意义: SAGE 是 05-skillrl SkillRL / 06-skill1 Skill1 同主题的早期工作 (skill 库与 RL 结合), 强调"一致的 skill 实现"——它指出纯 prompting 式 skill 库实现不稳定、改用 RL (SAGE=Skill-Augmented GRPO) 系统化。它属于本库 Skill 进化的"神经 RL 派", 其"Sequential Rollout 让 skill 跨相似任务累积"的设计, 与 SkillRL 的递归进化、Skill1 的统一三能力一脉, 共同探索"如何用 RL 让 skill 库与 policy 共进化"。

2026-01 (8 篇)

#4 Agentic Reasoning for Large Language Models 📖 [UIUC, 206↑] — arXiv 2601.12538 → 精读 [21-agentic-reasoning-survey](#) [分类⑧]

问题动机：agentic reasoning 领域快速膨胀但缺乏统一的体系化梳理——各种工作（ReAct、ToT、o1、Deep Research、self-evolving agent...）散落各处，缺一份按环境动态组织的、能定位所有工作的框架。

核心方法：这是本库最高票综述（UIUC，29 作者）。核心是按**环境动态**把 agentic reasoning 组织为**三层框架**：① **Foundational layer**——稳定设定下的单 agent 核心能力（planning、tool use、search）；② **Self-evolving layer**——agent 如何通过 **feedback / memory / adaptation** 三机制精炼能力、随时改进；③ **Collective multi-agent layer**——协作设定下的协调、知识共享、共同目标。第二维度区分 **in-context reasoning**（通过结构化编排 scale test-time 交互，不训练）与 **post-training reasoning**（通过 RL + SFT 优化行为，需训练）。综述覆盖科学、机器人、医疗、自治科研、数学等域，配套 Awesome 列表（1.3k★）。明确列出的 open challenges：personalization、long-horizon interaction、world modeling、scalable multi-agent training、governance。

关键结果：把 agentic reasoning 的术语体系、三层分类、两维优化路线整合为"统一 roadmap bridging thought and action"。

意义：本库的学术坐标系之一——它正式把 **Self-Evolving Layer** 确立为独立研究层（介于 foundational 与 collective 之间），而本库几乎所有论文都落在这一层。它与 [22-agentic-env-survey](#)（环境工程综述，环境视角）形成"agent 视角 + 环境视角"互补，共同为整个 evolve 主题定调。它明确把 governance（治理）、world modeling、scalable multi-agent training 列为未来方向——正是本库趋势 3.3 节"未来方向"的权威依据。精读见 [21-agentic-reasoning-survey](#)。

#23 Controlled Self-Evolution for Algorithmic Code Optimization (CSE) 📖 [QuantaAlpha, 115↑] — arXiv 2601.07348 → 精读 [13-cse](#) [分类③]

问题动机：自演化代码优化（如 AlphaEvolve）通过迭代循环增强代码生成，但**探索效率低**。三根因：

- ① **initialization bias**（初始化偏置把演化困在差解区域）；② **uncontrolled stochastic operations**（无反馈引导的随机操作）；③ **insufficient experience utilization**（跨任务经验利用不足）。

核心方法：**CSE** 三招针对性破解：① **Diversified Planning Initialization**——生成结构上不同的算法策略，广覆盖解空间（破初始化偏置）；② **Genetic Evolution**——用反馈引导的机制替代随机操作，支持**定向变异 + 组合交叉**（如 profiler 输出指导哪部分变，破无反馈随机）；③ **Hierarchical Evolution Memory**——在任务内 + 任务间两层捕捉**成功 + 失败经验**（破经验利用不足）。

关键结果：在 **EffiBench-X**（算法效率优化基准）上，CSE 跨多个 LLM backbone **全面超过所有基线**，**早期 generation 就高效、且持续改进**（vs 纯随机变异的样本效率低下）。代码 github.com/QuantaAlpha/EvoControl。

意义：CSE 把"自演化代码"从蒙特卡洛式随机搜索升级为**带先验的引导搜索**（diversified init + feedback-guided genetic + hierarchical memory），是该方向工程效率的关键一步。它与 [15-gigaevo](#)（AlphaEvolve 开源）、[14-quantaalpha](#)（金融 alpha）、BES（双向进化搜索）、TTT-Discover（测试时进化）共同构成"LLM × 进化算法"派，共性是把变异/交叉从盲目随机升级为反馈引导的受控演化。其"同时记成功+失败经验"也呼应本库"失败是养料"主线。精读见 [13-cse](#)。

#35 EvoCUA: Evolving Computer Use Agents via Learning from Scalable Synthetic Experience 📖 [美团, 92↑] — arXiv 2601.15876 → 精读 [02-evocua](#) [分类①]

问题动机：原生 CUA 的潜力被**静态数据 scaling**的天花板卡住——主流做法是被动模仿静态数据集，覆盖不了真实操作的长尾。

核心方法：EvoCUA 把 CUA 的**数据生成** ⇌ **策略优化**合并为自持演化循环。① **可验证合成引擎**——"Generation-as-Validation"范式，ReAct VLM "Task Architect"双流共生成指令 + 可执行 validator，闭环反馈在真实沙箱执行直到成功，扩到数万实例；② **数万异步 sandbox rollout**——持续 >100,000 并发沙箱，一分钟拉起数万实例；③ **按能力边界调控的迭代演化学习**——Cold-Start + RFT（Dynamic Compute Budgeting 把算力集中到 boundary queries）+ **失败回收 RL（Step-Level DPO）**：定位 Critical Deviation Step 做 Action Correction / Reflection and Recovery。失败轨迹 → 富监督信号（error analysis + self-correction）。

关键结果：**OSWorld 56.7%** 刷新开源 SOTA，反超闭源 UI-TARS-2（53.1%）、超 OpenCUA-72B（+11.7%）。经验 scaling：20k→226k→1M 数据，纯 RFT 增益 +2.61→+6.79→+8.12pp。

意义：EvoCUA 把"环境自动合成 + 大规模并行 RL + 失败回收"整合为可持续的工业级 CUA 生产线。它是本库"自造经验/环境"主线在 GUI 域的代表，与 [04-dreamgym](#)（合成经验）、[03-agent-world](#)（合成环境）呼应。**失败回收**（Step-Level DPO 定位关键分叉点）是本库"失败是养料"主线的标杆。它也是 agentic-rl 专题 [agentic-rl/06-evocua](#) 的同一工作。精读见 [02-evocua](#)。

#37 Evolving Programmatic Skill Networks (PSN) 📖 [蒙特利尔大学, 88↑] — arXiv 2601.03509 → 精读 [07-psn](#) [分类②]

问题动机：在开放式具身环境里，agent 必须构造、精炼、复用**一个不断扩张的可执行 skill 库**。如何让这种 skill 库稳定演化而不退化？

核心方法：**PSN（Programmatic Skill Network）**的核心立场是 **skill = 可执行符号程序**，组成一个可组合网络（compositional network）随经验进化（区别于神经 policy 的隐式表征）。三机制（由 LLM

实例化)：① **REFLECT**——对 skill 组合做**结构化故障定位**（精确找到是哪个 sub-skill 出错）；② **maturity-aware update gating**——成熟可靠的 skill 稳定保留、不确定的 skill 保持可塑性（平衡 stability vs plasticity）；③ **canonical structural refactoring**——在 **rollback validation**（回滚验证）下做规范化重构，维持网络紧凑性。关键洞察：**PSN 的学习动态与神经网络训练结构同构**（structural parallels）。

关键结果：在 MineDojo / Crafter 等开放式任务分布上展示**强 skill 复用、快速适应、强泛化**。计划开源。

意义：PSN 是 Skill 进化的**程序化派**代表（区别于 05-skillrl 的神经 RL 派、09-skillsvote 的自然语言文档派）——skill 是可执行符号程序而非神经权重或 markdown。其 **maturity-aware gating + rollback validation** 是本库"防对抗崩溃/防退化"主线的代表机制。它发现的"skill 进化 $\approx$ 神经网络训练"同构，是本库趋势 方向⁵ "自演化理论化"的重要线索（虽仍是经验类比）。精读见 07-psn。

#73 ArenaRL: Scaling RL for Open-Ended Agents via Tournament-based Relative Ranking 📄 [阿里 NLP, 54↑] — arXiv 2601.06487 [分类④]

问题动机：RL 在可验证 outcome 任务上提升显著，但在**开放式 agent 任务**（如复杂旅行规划，解空间巨大、无客观 ground-truth）上挣扎。因缺客观答案，现有 RL 靠 reward model 给单个响应打**标量分**——但 pointwise scoring 有**discrimination collapse**：reward model 难分辨轨迹间的细微优势，组内分数被压缩到窄区间，有效奖励信号被 reward model 噪声淹没，优化停滞。

核心方法：**ArenaRL** 从 pointwise 标量打分转向**组内相对排名**（intra-group relative ranking）。① **process-aware pairwise evaluation**——用多级 rubric 给轨迹细粒度相对分；② **intra-group adversarial arena**——构建组内对抗竞技场 + **tournament-based ranking**（锦标赛式排名）得稳定 advantage 信号；③ **seeded single-elimination scheme**（种子单淘汰）——以 **O(N)** 复杂度达到接近完整 pairwise ($O(N^2)$) 的 advantage 估计精度。配套构建 **Open-Travel** 和 **Open-DeepResearch** 两个全周期基准（覆盖 SFT、RL、多维评估）。

关键结果：种子单淘汰以 $O(N)$ 达到接近 $O(N^2)$ 完整 pairwise 的精度；ArenaRL 大幅超标准 RL 基线，让 agent 在复杂真实任务上产出更鲁棒的解。254★。

意义：ArenaRL 为"开放式、无标准答案"任务的演化式 RL 提供**可扩展的相对评价信号**——用锦标赛相对排名替代标量打分，破解 discrimination collapse。它与 SCOPE（自判 rubric）、OpenSkill（自造 verifier）共同探索"开放式任务如何获得可靠奖励信号"，是本库"开放世界 bootstrap"主线在"评价信号"侧的代表。其 $O(N)$ 锦标赛 vs $O(N^2)$ pairwise 的效率权衡也呼应 方向⁸ "让自演化用得起"。

#81 UniCorn: Towards Self-Improving Unified Multimodal Models through Self-Generated Supervision 📄 [中科大, 51↑] — arXiv 2601.03193 [分类⑦]

问题动机：统一多模态模型（UMM）在跨模态理解上成功，但难以把内部理解转化为高质量生成。作者把这一鸿沟形式化为 "**Conduction Aphasia**"（传导性失语）——模型能准确解读多模态输入，却难转化为忠实可控的合成（"看懂了但画不出"）。

核心方法：UniCorn 是一个简洁优雅的自改进框架，无需外部数据。把单个 UMM 切成三协作角色：**Proposer-Solver-Judge**，通过 **self-play** 产生高质量交互，并用 **cognitive pattern reconstruction**（认知模式重构）把潜在理解蒸馏为显式生成信号（把"理解"转化为"生成线索"）。配套 **UniCycle** 基准——基于 Text→Image→Text 重构循环的 cycle-consistency 基准。

关键结果：在 6 个通用图像生成基准上达 SOTA——**TIIF 73.8、DPG 86.8、CompBench 88.5、UniCycle SOTA**，WISE +5.0、OneIG +6.5，同时保持理解能力。全自监督精炼。173★。

意义：UniCorn 把 self-play 三角色范式应用到"理解→生成"鸿沟上——Proposer-Solver-Judge 比双角色多了 Judge 这一裁判角色，且无需外部数据/teacher。它与 VisPlay（双角色）、MM-Zero（Proposer-Coder-Solver 三角色）、Agent0-VL（Solver-Verifier）共同把自演化推广到多模态，各自解决模态特有难题（UniCorn 解决"理解-生成传导"）。其"无外部数据 + 三角色 self-play"是宝库"zero-data 自造数据"主线在 UMM 上的体现。

#88 Beyond Static Tools: Test-Time Tool Evolution for Scientific Reasoning (TTE) 📄 [上海 AI Lab, 48↑] — arXiv 2601.07641 [分类②]

问题动机：AI for Science 的核心挑战不只是推理，而是在开放式科学世界中创造计算方法的能力。现有 LLM agent 依赖静态、预定义的工具库——这一范式在科学域根本失效，因为科学工具稀疏、异构、本质不完备（你永远无法预先备齐所有需要的工具）。

核心方法：TTE（Test-Time Tool Evolution）让 agent 在推理时合成、验证、进化可执行工具——三阶段：**Synthesize**（按具体问题生成可执行工具）→ **Verify**（用前检查）→ **Evolve**（精炼并跨域适配）。把工具从固定资源变为问题驱动的产物（problem-driven artifacts），克服静态工具库的僵化与长尾局限。配套 **SciEvo** 基准——1,590 个科学推理任务，由 925 个自动进化的工具支撑。

关键结果：TTE 在准确率与工具效率上达 SOTA，并实现计算工具的有效跨域适配。代码 github.com/lujiaxuan0520/Test-Time-Tool-Evol。13 作者。

意义：TTE 把"进化"从 skill 扩展到工具——这是宝库"进化单位上移"趋势（方向📍6）的关键一例：单能力→skill→工具→环境→记忆→组织。它证明在科学这种"工具本质不完备"的域，静态工具库必败、必须 test-time 动态造工具。它与 SkillNet（skill 基建）、SkillsVote（skill 治理）共享"可复用能力资产"思想，但把对象从 skill 换成可执行工具，且强调"推理时进化"而非"训练时积累"。

#95 Learning to Discover at Test Time (TTT-Discover) 📄 [Stanford, 45↑] — arXiv 2601.16175 [分类③]

问题动机：如何用 AI 为一个科学问题发现新的 SOTA？此前的 test-time scaling 工作（如 AlphaEvolve）通过 **prompt** 一个冻结的 **LLM** 来搜索——但这把搜索局限在模型已有的能力内，无法针对单一难题积累专属经验。

核心方法：TTT-Discover 在测试时做 **RL (test-time RL)** ——让模型在测试问题上**继续训练**，用该问题专属的经验改进。这是一种特殊的持续学习：目标是"产生一个极好的解"而非"平均很多好解"——为此**学习目标与搜索子程序都设计为优先最有希望的解**（区别于标准 RL 优化平均性能）。聚焦连续奖励（continuous-reward）问题。用 **OpenAI gpt-oss-120b (开源权重)**（对比此前最佳需闭源 frontier 模型）+ Thinking Machines 的 Tinker API，**每问题成本几百美元**。

关键结果：在几乎所有尝试的问题上达到新 SOTA——数学（Erdős minimum overlap 问题、autocorrelation inequality）、GPU kernel 工程（GPUMode 竞赛，**比此前最佳快 2×**）、算法设计（过往 AtCoder 竞赛）、生物（单细胞去噪）。解由专家/组织者审核，代码公开。

意义：TTT-Discover 把 test-time training 与演化式发现结合，是"**为单一难题专门进化**"的代表——它与 AlphaEvolve（冻结 LLM 搜索）的本质区别是"让模型在测试问题上继续 RL 训练"。它属本库演化式优化派，但独特之处是"用开源模型 + 低成本（几百美元）达到此前需闭源 frontier 才有的发现能力"，呼应趋势方向⁸"让自演化用得起"。其"优先一个极好解而非平均好解"的学习目标，是发现型任务区别于通用 RL 的关键。585★。

2026-02 (7 篇)

#17 QuantaAlpha: An Evolutionary Framework for LLM-Driven Alpha Mining 📄 [QuantaAlpha, 190↑] — arXiv 2602.07085 → 精读 [14-quantaalpha](#) [分类③]

问题动机：量化金融的 alpha 因子挖掘需要在**噪声大、非平稳**的市场上做结构化探索与跨迭代精炼。如何把演化式 agent 落地到这一实战领域？

核心方法：QuantaAlpha 把**每次端到端挖掘运行当作一条 trajectory**，做**轨迹级变异 / 交叉**：**Mutation** 定位次优步骤做定向修订；**Crossover** 重组互补的高奖励片段、复用有效模式。两个约束：① **语义一致性约束**——强制"假设 → 因子表达式 → 可执行代码"三层对齐（hypothesis 必须能解释 factor，factor 必须能映射到 code）；② **anti-crowding 复杂度约束**——约束因子复杂度与冗余、缓解 crowding（防过拟合）。

关键结果：用 GPT-5.2 在 **CSI 300** 上 **IC 0.0472、ARR 4.68%、MDD 11.8%**；CSI 300 上挖出的因子迁移到 **CSI 500 / S&P 500** 不经重训，四年累计超额收益 **~40.28% / ~19.1%**——验证跨市场泛化与对

市场分布漂移的鲁棒性。1.1k★。17 作者。

意义：QuantaAlpha 在金融领域罕见地达到"AI 自主发现 alpha 因子"的实战级别，展示 LLM agent 在领域专家任务上的潜力。它的**轨迹级变异/交叉**（而非传统因子级遗传算法）+ 语义一致性约束是演化式优化派的领域落地代表，与 [13-cse](#)（代码）、[15-gigaev0](#)（AlphaEvolve 开源）同源。其跨市场零样本迁移（CSI 300→CSI 500/S&P 500）证明演化出的能力可泛化，是该方向少见的真实经济价值验证。精读见 [14-quantaalpha](#)。

#42 SkillRL: Evolving Agents via Recursive Skill-Augmented Reinforcement Learning 📖 [UNC, 76↑] — arXiv 2602.08234 → 精读 [05-skillrl](#) [分类②]

问题动机：LLM agent 常孤立运作、不从过去经验学习。已有 memory-based 方法主要存 raw trajectory——冗长、冗余、噪声大，提不出"高层、可复用的行为模式"，泛化受限。

核心方法：SkillRL 用自动技能发现 + 递归进化连接 raw experience 与 policy 改进。① **Experience-based Skill Distillation**——teacher (o3) 蒸馏轨迹，同时保留成功与失败（成功提策略模式、失败合成简洁教训），10–20× token 压缩；② **层级 SkillBank**——General + Task-Specific 两级，每 skill 有 name/principle/when_to_apply；③ **Adaptive Retrieval**（通用恒含 + 任务特定按相似度 TopK，K=6）；④ **Recursive Skill Evolution**——cold-start SFT 后做 RL，仅在 Acc<δ 处触发演化（采样失败轨迹生成新 skill），形成良性循环。RL 用 GRPO。

关键结果：ALFWorld 89.9%（超 GRPO +12.3%）、WebShop 72.7%，超 GPT-4o +41.9%；7 个搜索 QA 平均 47.1%。技能库 55→100 skill（Step 150）。Ablation：去层级 -13.1%、去 skill 库 -25%。833★。

意义：SkillRL 解决 memory-based agent 的核心痛点（raw trajectory 冗余），用"蒸馏成 skill + 递归进化"替代"存原始轨迹"，库与 policy 共进化。它是 Skill 进化神经 RL 派的代表，与 [01-agent0](#) 同组（aiming-lab），把自演化从推理层推进到 skill 层。它也是 agentic-rl 专题 [agentic-rl/14-skillrl](#) 的同一工作。精读见 [05-skillrl](#)。

#52 MARS: Modular Agent with Reflective Search for Automated AI Research 📖 [Google, 67↑] — arXiv 2602.02660 [分类⑥]

问题动机：自动化 AI 研究（尤其复杂的 ML 工程 MLE 任务）面临两难——**评估昂贵**（要训模型）、**归因不透明**（难判断是哪个因素带来性能）。现有 LLM agent 倾向生成**单体脚本**，既忽略执行成本也忽略因果因素。

核心方法：MARS 三支柱：① **Budget-Aware Planning**——用**成本约束的 MCTS**（Monte Carlo Tree Search）平衡性能与执行开销；② **Modular Construction**——用 **Design-Decompose-Implement** 管线管理复杂研究仓库（而非单体脚本）；③ **Comparative Reflective Memory**——通过对比分析不同解的差异来做 credit assignment、提取高信号洞察。

关键结果：在 **MLE-Bench** 上达到开源框架 SOTA（同等设定），与全球排行榜顶尖方法有竞争力；展示"Aha!"时刻——**63% 的有用 lesson 来自 cross-branch transfer**（搜索路径间的洞察迁移），说明洞察能有效泛化。ICML 2026。

意义：MARS 把"反思 + 记忆"用于 agent 设计研究流程，自改进研究能力——它属本库"组织级/元自改进"分类（agent 改进研究过程本身）。其 **Comparative Reflective Memory**（对比解的差异做归因）是一种精细的 credit assignment，呼应本库"失败/对比是养料"主线。它与 Hyperagents（自指元进化）、Memento-Skills（agent 设计 agent）、CORAL（多 agent 开放式发现）共同代表"进化单位上移到研究/设计流程"。

#55 MemSkill: Learning and Evolving Memory Skills for Self-Evolving Agents [南洋理工, 63↑] — arXiv 2602.02474 [分类⑤]

问题动机：现有 memory 系统靠少量静态、手工的记忆操作（提取/巩固/剪枝），这些操作硬编码了人类先验，僵化且低效——"什么该提取、怎么巩固、何时剪枝"其实高度任务依赖。

核心方法：MemSkill 受 agent skill 哲学启发，把记忆操作重构为可学习、可进化的"记忆 skill"。**controller** 学习选择少量相关"记忆 skill"（提取/巩固/剪枝信息的结构化可复用例程），**LLM executor** 产出 skill-guided 记忆，**designer** 复盘难例并演化 skill 集。即把"怎么记"从人类先验变成可学习、可随经验演化的 skill 库。

关键结果：在 self-evolving agent 场景下，可学习的 memory skill 优于固定记忆操作。506★。

意义：MemSkill 把"skill 进化"思想注入记忆系统——记忆操作本身也能进化。它是本库"记忆进化"分类的代表，与 memory/ 专题的同一工作（[memory/11-memskill-memento](#)）交叉。它与 TaskMem（RL 学 memorization policy）、Need Sleep（睡眠巩固）共同探索"记忆的写入/巩固策略应可学习/可演化而非硬编码"，是"进化单位上移到记忆"（方向⑥）的代表。

#61 SWE-Universe: Scale Real-World Verifiable Environments to Millions [Qwen, 61↑] — arXiv 2602.02361 [分类④]

问题动机：从 GitHub PR 自动构建可验证 SWE 环境面临三难——低产出（production yield）、弱验证器、高成本。如何规模化到百万级真实可验证环境，支撑 agentic mid-training + RL？

核心方法：**SWE-Universe** 是一个可扩展高效的框架，用一个自训的高效模型驱动的 building agent 自动从 PR 构建环境。两个关键机制保证高保真可验证任务生成：① **iterative self-verification**（迭代自验证，重复验证循环确认任务正确性）；② **in-loop hacking detection**（环内 hacking 检测，构建过程中就抓 reward-hacking/shortcut 行为）。规模化到 **807,693 个多语言环境**。

关键结果：百万级（807,693）多语言可验证环境；应用到 Qwen3-Max-Thinking 上 **SWE-Bench Verified 75.3%**。通过大规模 agentic mid-training + RL 验证环境价值。18 作者。

意义：SWE-Universe 为"环境协同进化"提供**百万级真实环境基建**——它解决了"从 PR 自动构环境"的三难（低产出/弱验证/高成本），用 self-verification + in-loop hacking detection 保证质量。它与 03-agent-world（自演化环境合成）、AutoEnv（跨环境）、16-autoenv 共同把"环境"做成一等公民，是本库"环境从背景变一等公民"主线（方向7）的规模化代表，且与 daVinci-Agency（PR 序列作长程监督）同样从软件演化挖监督。

#67 SkillOrchestra: Learning to Route Agents via Skill Transfer 📄 [威斯康星大学, 58↑] — arXiv 2602.19672 [分类②]

问题动机：复合 AI 系统（compound AI）的成败取决于编排。但现有方法有两弱点：① **input-level router** 做粗粒度 query 级决策、忽略演化中的任务需求；② **RL 训练的 orchestrator** 适配成本高、易"routing collapse"（反复调用同一个强但贵的选项）。

核心方法：SkillOrchestra 不直接端到端学路由策略，而是从**执行经验学习细粒度 skill**——蒸馏出可复用能力，建模各 agent 在不同 skill 下的能力与成本（显式的 capability/cost 画像），部署时估计当前交互需要哪些 skill、按 skill 需求路由（在显式性能-成本权衡下选 agent）。这种显式 skill 建模缓解 routing collapse（选择基于 skill 适配而非对某个强 agent 的学习偏好）。

关键结果：10 个基准上，比 SOTA RL-based orchestrator 高**最高 22.5%**；学习成本比 **Router-R1** 低 **700×**、比 **ToolOrchestra** 低 **300×**——"可扩展、可解释、样本高效"。代码 github.com/jiayuwu/SkillOrchestra。

意义：SkillOrchestra 把 skill 学习用于**多 agent 编排**，缓解路由塌缩——它把编排从"训练大模型当 router"（贵、易塌缩）推到"基于 skill 学习的轻量路由"（700× 更省、可解释）。它属 Skill 进化分类，但应用方向独特（编排而非求解），与 ToolOrchestra（NVIDIA, RL 编排）形成对比，呼应趋势方向 8 "低成本"。其"显式 capability/cost 画像 + 按 skill 需求路由"是可解释编排的代表。64★。

#82 daVinci-Agency: Unlocking Long-Horizon Agency Data-Efficiently 📄 [SII-GAIR, 53↑] — arXiv 2602.02619 [分类④]

问题动机：LLM 在短任务上表现好，但**长程 agentic 工作流**上挣扎，核心瓶颈是缺乏捕捉"长依赖结构 + 跨阶段演化动态"的训练数据——现有合成方法要么局限单一特征场景、要么需昂贵人工标注。

核心方法：daVinci-Agency 把数据合成**重新理解为真实软件演化**——论证 **Pull Request (PR)** 序列天然蕴含长程学习的监督信号。从 chain-of-PRs 挖掘监督，三个互锁机制：① **渐进任务分解**（通过连续 commit）；② **长期一致性强制**（通过统一功能目标）；③ **可验证精炼**（来自真实 bug-fix 轨迹）。相比合成替代，**PR-grounded 结构**天然保留因果依赖与迭代精炼。

关键结果：每条轨迹平均 ~85k token、**116 次 tool call**；仅用 **239 个训练样本** fine-tune GLM-4.6，就在 **Toolathlon** 上获得 **47% 相对增益**——数据效率极高。

意义：daVinci-Agency 用"软件演化轨迹（PR 序列）"作为长程 agent 的高质量监督来源——它的洞察是"真实 PR 链天然编码了长程任务的长依赖 + 跨阶段一致性"，且数据效率惊人（239 样本 47% 增益）。它与 memory/ 专题同一工作交叉，与 SWE-Universe（百万级 PR 环境）同样从软件演化挖价值，是本库"自造数据/环境"主线在"长程监督数据合成"侧的代表。

2026-03 (5 篇)

#41 SkillNet: Create, Evaluate, and Connect AI Skills 📄 [浙大, 94↑] — arXiv 2603.04448 → 见 [10-skillnet](#) [分类②]

问题动机：现有 AI agent 能灵活调工具、执行复杂任务，但长期进步受限于缺乏 skill 的系统性积累与迁移——没有统一的 skill 巩固机制，agent 频繁"reinvent the wheel"（在孤立上下文里重复发现解法）。

核心方法：SkillNet 是大规模 skill 开源基础设施。用统一 ontology 组织 skill，支持从异构来源创建 skill、建立丰富的关系连接、做 5 维评估：**Safety**（安全）/ **Completeness**（完整性）/ **Executability**（可执行性）/ **Maintainability**（可维护性）/ **Cost-awareness**（成本感知）。配套三件套：20 万+ skill 仓库 + 交互平台 + Python 工具包。

关键结果：在 ALFWorld / WebShop / ScienceWorld 三大长任务、多个 backbone 上——平均奖励 +40%、执行步数 -30%。把 skill 当"演化、可组合的资产"，让 agent 从"短暂经验"走向"持久精通"。项目页 skillnet.openkg.cn。49 作者。

意义：SkillNet 把 skill 从单个论文/项目级别推到生态级——首次给 skill 提出系统化质量标准（5 维评估），并提供 20 万级仓库 + 平台 + 工具包，类似"PyPI 之于 Python 包"。它与 [09-skillsvote](#) SkillsVote（治理）、HF SkillClaw（集体进化）共同代表 skill 的"基建侧/生态侧"工作，关键词从"产生 skill"转向"组织/评估/连接 skill"。1.0k★。

#68 Online Experiential Learning for Language Models (OEL) 📄 [Microsoft Research, 60↑] — arXiv 2603.16856 [分类①]

问题动机：主流范式靠离线训练（人工标注或模拟环境），把部署期积累的丰富经验完全浪费了一一模型在真实使用中遇到的大量交互轨迹没被用来改进。

核心方法：OEL (Online Experiential Learning) 让模型从自己的部署经验持续改进，两阶段：① 知识提取——从用户侧收集的交互轨迹中提取并积累可迁移的经验知识；② 参数巩固——通过 on-policy context distillation 把经验巩固进模型参数（无需访问用户侧环境）。两阶段迭代成在线学习闭环（更好的模型收集更高质量轨迹→产生更丰富经验→下一轮）。在文本游戏环境、多个模型规模 + thinking/non-thinking 变体上评测。关键分析：提取的经验知识显著比 raw 轨迹更有效；知识源与 policy 模型的 on-policy 一致性对有效学习至关重要。

关键结果：跨迭代一致提升，同时改善任务准确率与 token 效率，且保持 OOD 性能。作者含 Li Dong、Furu Wei (MSR)。

意义：OEL 把"部署即学习"形式化——**经验进权重**（而非只存外部记忆）。它的两阶段（提取经验知识→on-policy context distillation 巩固进参数）是 frozen-deployment 场景下持续学习的代表，与 18-evoarena 的记忆视角、本库经验主线呼应。其"经验知识 >> raw 轨迹"的发现与 SkillRL 05-skillrl"存模式不存轨迹"同源。它来自 MSR（与 agentic-rl 的 ERL、LLM-in-Sandbox 同组系），代表"从真实部署经验在线进化"方向。

#74 Memento-Skills: Let Agents Design Agents 📄 [UCL, 58↑] — arXiv 2603.18743 〔分类⑥〕

问题动机：如何做一个通用、可持续学习的系统，能**自主构造/适配/改进任务专属 agent**——即让 agent 设计 agent？

核心方法：Memento-Skills 基于 **memory-based RL + stateful prompts**。可复用的 skill 以**结构化 markdown 文件**作为**持久、进化的记忆**；从简单 skill（web 搜索/终端）出发，通过 **Read-Write Reflective Learning**（读阶段 skill router 选 skill、写阶段更新/扩充 skill 库）持续改进。**不更新 LLM 参数**，全靠外化的 skill/prompt 演化实现 agent 自改进。

关键结果：在多任务上通过 skill 库读写演化实现持续改进。1.5k★。

意义：Memento-Skills 把进化单位提升到"**agent 设计 agent**"，skill = 进化记忆。它与 memory/ 专题同一工作交叉（[memory/11-memskill-memento](#)）。它属本库"组织级/元自改进"分类，与 Hyperagents（自指元进化）、MARS（自改进研究流程）共同代表"进化单位上移到 agent 设计/元机制"（方向 6/9）。其"记忆=可演化 markdown skill + 不动权重"是 frozen-model 时代的实用路线，与 09-skillsvote、HF SkillOpt 同立场。

#83 MM-Zero: Self-Evolving Multi-Model Vision Language Models From Zero Data 📄 [NVIDIA, 54↑] — arXiv 2603.09206 〔分类⑦〕

问题动机：自演化已成改进 LLM/VLM 的关键范式。LLM agent 能从零数据自演化，但 **VLM 因视觉模态通常需要种子数据（如图像）来 bootstrap**——MM-Zero 要突破这一限制，实现 VLM 的零数据自演化。

核心方法：MM-Zero 是**首个 RL-based 零数据 VLM 推理自演化框架**。超越此前的 dual-role（Proposer/Solver），引入**三专门角色**：**Proposer**（生成抽象视觉概念、formulate 问题）+ **Coder**（把概念翻译成可执行代码 Python/SVG 来**渲染图像**）+ **Solver**（对生成内容做多模态推理）。三角色都从**同一 base model** 初始化，用 **GRPO** 训练，奖励整合**执行反馈 + 视觉验证 + 难度平衡**。关键是 **Coder 生成可渲染图像** → 移除了对种子图像数据的需求（图像是 agent 自己用代码画出来的）。

关键结果：在多个多模态基准上提升 VLM 推理性能。75★。

意义：MM-Zero 把 01-agent0 式零数据自演化彻底推广到多模态——它的巧思是用 **Coder** 角色生成可渲染图像，绕过了"VLM 自演化需种子图像"的根本障碍。它与 VisPlay（双角色、用无标注图像）、UniCorn（三角角色、理解→生成）、Agent0-VL（工具自评）共同构成多模态自演化谱系，是其中"零数据"最彻底的一支（连图像都自己造）。它代表本库"zero-data bootstrap"主线在视觉模态的极限。

#88 Hyperagents 📄 [Meta FAIR, 51↑] — arXiv 2603.19461 [分类⑥]

问题动机：**Darwin Gödel Machine (DGM)** 在 coding 域实现了开放式自我改进——因为评估和自我修改本身都是 coding 任务，coding 能力增益能直接转化为自我改进能力增益。但这一对齐在 coding 域外不成立（在非 coding 任务上，解题能力变强不等于改进自己的能力变强）。

核心方法：**Hyperagents** 是自指（self-referential）agent——把两个组件整合进一个可编辑的程序：**task agent**（解目标任务）+ **meta agent**（修改自己和 task agent）。关键创新是元层修改过程本身也可编辑，实现 **metacognitive self-modification**（元认知自我修改）——不只改进解题行为，还改进"产生未来改进的机制"本身。实例化为 **DGM-H**（扩展 DGM），移除 coding-specific 对齐假设，使其"潜在支持任何可计算任务上的自加速进步"。

关键结果：DGM-H 跨多样域随时间提升，超过无自我改进/无开放式探索的基线及此前自改进系统；改进自己的 agent 生成过程（如持久记忆、性能追踪），且这些元层增益跨域迁移、跨运行累积。代码 facebookresearch/Hyperagents。2.6k★。

意义：Hyperagents 是元/自指自改进的前沿探索——它诊断出 DGM 的"coding 域对齐"局限，并用"元层修改过程本身可编辑"把自我改进推广到非 coding 域。它"不只搜索更好的解，而是持续改进自己如何改进"，是本库趋势方向📌"递归/元自改进——从改能力到改改进机制"的旗帜。它与 Memento-Skills（agent 设计 agent）、MARS（自改进研究）共同把进化单位推到最高层（agent 的学习机制本身），也是通往"超级智能"叙事最核心、最难、最具风险的方向。

2026-04 (9 篇)

#7 SkillClaw: Let Skills Evolve Collectively with Agentic Evolver 🔗 [293↑] — arXiv 2604.08377 → 已在 huggingface/11-skillclaw.md 精读 [分类②]

问题动机：当 10 万用户都在用同一个 agent 服务时，他们的交互轨迹蕴含远比单用户更丰富的 skill 改进信号——如何把跨用户、跨时间的 trajectory 作为改进 skill 的主要信号，实现生态级集体技能进化？

核心方法：SkillClaw 把 skill 学习从"单 agent 自演化"推到"跨用户共享演化"。① 跨用户跨时间轨迹聚合作为改进 skill 的主要信号；② **Autonomous Evolver**——自动识别"很多用户都在重复尝试类似任

务"的 pattern → 翻译为 skill 更新（精炼现有或扩展新 skill）→ 同步到**共享 skill 仓库**供所有用户受益；③ 隐私保护机制确保用户隐私不泄露到 skill 中。在自建 WildClawBench 上用 Qwen3-Max 验证。

关键结果：显示 skill 库随用户数增长而持续提升。1.9k★。

意义：SkillClaw 把 skill learning 从研究 demo 推到"**持续运营的产品级**"——生态级集体技能进化（多用户轨迹聚合）。它与本库 09-skillsvote（治理）、05-skillrl（共进化）同属 skill 进化主线，但尺度最大（生态级而非单 agent/单策略）。详见 huggingface/11-skillclaw.md，本库做索引与交叉引用。它代表"进化单位上移到多用户生态"，呼应趋势 方向³ "进化单位继续上移"。

#28 From Skills to Talent: Organising Heterogeneous Agents as a Real-World Company (OneManCompany) 📄 [1mancompany, 121↑] — arXiv 2604.22446 → 见 19-onemancompany 〔分类⑥〕

问题动机：单 agent 已通过模块化 skill/tool 进步，但 multi-agent 系统仍受限于**固定结构、紧耦合协调、会话内学习**。根因是缺一个**组织层**——管理 agent 如何被"组装、治理、随时间改进"，且这一层应与单个 agent 知道什么解耦。

核心方法：OneManCompany (OMC) 把 multi-agent 系统提升到**组织层**。三组件：① **Talent**——把 skill/tool/runtime config 封装为**可移植的 agent 身份**（类似员工档案），通过"抽象异构后端的类型化组织接口"协调；② **Talent Market**——社区驱动的**按需招募**机制（项目缺能力就找符合条件的 Talent），让组织"在执行中动态闭合能力缺口、重新配置自己"；③ **Explore-Execute-Review (E²R)** 树搜索——任务自顶向下分解为"可问责单元"、结果自底向上聚合驱动系统性审查与精炼，**形式化保证终止性与无死锁**。

关键结果：在 PRDBench（项目需求文档基准）上**成功率 84.67%**，超此前 SOTA +15.48pp；跨域案例研究展示通用性。33 页。

意义：OMC 把进化的单位从"单 agent"提升到"**agent 组织**"——self-improving AI organizations。它把组织行为学 insights（Talent 档案、人才市场、招募/重配）引入 multi-agent 设计，**E²R 的终止性/无死锁形式化证明**是工程严谨性的体现。它对 enterprise agent application 有直接参考价值，是本库"进化单位上移到组织级"（方向³）的代表，与 CORAL（多 agent 开放式进化）、Hyperagents（元进化）共同推进"从单 agent 到组织/生态"。

#43 Programming with Data: Test-Driven Data Engineering for Self-Improving LLMs (ProDa) 📄 [OpenDataLab, 89↑] — arXiv 2604.24819 → 见 20-proda 〔分类④〕

问题动机：把专业人类知识从文本可靠迁移进 LLM 是根本挑战。fine-tuning 在领域语料上**没有反馈**——模型失败时无法诊断数据缺陷，只能"无差别加更多数据"。

核心方法：ProDa 的核心洞察——从源语料抽取的**结构化知识表示**同时作为训练数据与评估的共同基础，使数据工程生命周期对应软件开发生命周期：**训练数据=源码**（指定模型该学什么）、**模型训练=编译**、**benchmark=单测**、**失败驱动的数据修复=debugging**。在此对应下，模型失败分解为 **concept-level gaps**（概念缺口）与 **reasoning-chain breaks**（推理链断裂），可追溯到"数据的具体缺陷"并通过**定向 patch 修复**，每个修复循环"跨模型规模与架构产生一致提升、不损通用能力"。

关键结果：覆盖 **16 个学科**（自然科学、工程、生物医、社会科学）；开源结构化知识库 + benchmark 套件 + 训练语料。57 页。

意义：ProDa 让 fine-tuning 从"盲目加数据"变成"**有反馈的迭代修复**"——把软件工程的 test-driven debugging 范式搬到数据工程。它证明"训练数据与模型行为的关系是结构上可追溯、系统上可修复的"。它属本库"自造数据/失败驱动"主线，与 [02-evocua](#)（失败转监督）、CSE [13-cse](#)（记失败经验）共同代表"失败是养料"（方向[10](#)），但独特在于把失败精确归因到数据缺陷并定向修复。

#46 Agent-World: Scaling Real-World Environment Synthesis for Evolving General Agent Intelligence 📖 [字节 Seed, 85↑] — arXiv 2604.18292 → 精读 [03-agent-world](#) [分类④]

问题动机：LLM 越来越被期望作为通用 agent 与外部有状态工具环境交互，但训练受限于**真实环境稀缺** + **缺乏有原则的终身学习机制**。MCP 与 agent skill 提供统一接口，但如何规模化合成可验证环境？

核心方法：Agent-World 是自演化训练竞技场。两组件：① **Agentic Environment-Task Discovery** ——agent 自主探索数千真实环境主题的主题对齐数据库 + 可执行工具生态，合成可验证、难度可控的任务；② **Continuous Self-Evolving Agent Training** ——多环境 RL + 自演化竞技场（自动通过动态任务合成识别能力缺口），实现 **agent policy** 与环境的协同进化（co-evolution）。

关键结果：23 个高难基准，**Agent-World-8B/14B** 一致超越强专有模型和环境 **scaling 基线**；揭示"环境多样性 × 演化轮数"两条 scaling 趋势。20 作者。

意义：Agent-World 把"自演化环境合成"工程化为基础设施级 capability——agent 自己发现数据/工具、合成可验证任务、在竞技场识别缺口、policy 与环境共进化。它是本库"环境从背景变一等公民"（方向[7](#)）与"agent-environment co-evolution"的代表，与 [16-autoenv](#)（跨环境）、SWE-Universe（百万环境）、[18-evoarena](#)（环境演化评测）呼应。它也是 agentic-rl 专题 [agentic-rl/00-summary](#) 的同一工作。精读见 [03-agent-world](#)。

#49 OpenGame: Open Agentic Coding for Games 📖 [81↑] — arXiv 2604.18394 → 见 [17-opengame](#) [分类②]

问题动机：游戏开发处于创意设计与复杂软件工程交叉点，需协调游戏引擎、实时循环、跨多文件紧耦合状态。LLM/code agent 能解孤立编程任务，但被要求从高层设计产出**完整可玩游戏**时持续翻车（崩于跨文件不一致、场景接线断裂、逻辑不连贯）。

核心方法：OpenGame 是首个端到端 web 游戏创建的开源 agentic 框架。核心是 **Game Skill**（可复用、进化的能力）：**Template Skill**（从经验生长项目骨架库，scaffold 稳定架构）+ **Debug Skill**（维护"已验证修复的活协议"，系统性修复集成错误而非补孤立语法 bug）。模型 **GameCoder-27B** 三阶段：CPT（持续预训练专精游戏引擎）→ SFT → 执行驱动 RL。评测 **OpenGame-Bench**——因"验证可玩性比检查静态代码更难"，用无头浏览器执行 + VLM 评判三维度（Build Health / Visual Usability / Intent Alignment）。

关键结果：150 个多样游戏 prompt 上建立新 SOTA。2.5k★。

意义：OpenGame 把"skill 从经验进化"落地到游戏开发——skill 既长骨架（Template）也长修复经验（Debug）。它属 Skill 进化分类，把 coding agent 从"补全片段"推到"创造完整产品"。它与 agentic-rl 专题 [agentic-rl/00-summary](#) 的同一工作交叉。其"Template/Debug 双 skill 从经验累积"是本库"skill 从经验进化"的具体落地，OpenGame-Bench 对"难验证交互产物"的三维评测也有借鉴。

#69 SpatialEvo: Self-Evolving Spatial Intelligence via Deterministic Geometric Environments 📄 [浙大 REAL, 63↑] — arXiv 2604.14144 [分类⑦]

问题动机：3D 空间推理是具身智能核心，但持续改进受几何标注成本瓶颈。自演化范式有前景，但其依赖模型共识造伪标签会强化而非纠正模型自身的几何错误（大家一起错，错误被放大）。

核心方法：SpatialEvo 的关键洞察——3D 空间推理的 ground truth 是几何的确定性结果，可从点云和相机位姿精确算出，无需模型参与。据此构建 **Deterministic Geometric Environment (DGE)**：把 16 类空间推理任务形式化为显式几何验证规则，把无标注 3D 场景转为***"零噪声交互式 oracle"——用客观物理反馈替代模型共识，打破伪标签自我强化的循环。单个共享参数 policy** 在 questioner（产物理有效的场景锚定问题）和 solver（对 DGE 验证的 ground truth 求精确答案）两角色间共进化。**task-adaptive scheduler** 自动把训练集中到模型最弱的类别，产生无需手工设计的动态课程。

关键结果：9 个基准上，**3B** 和 **7B** 规模都拿最高平均分，空间推理一致提升、通用视觉理解无退化。80★。

意义：SpatialEvo 用"确定性几何"打破自演化的伪标签自我强化困局——这是它针对 3D 空间模态的巧思（几何 ground truth 可精确计算、无需模型自评）。它是本库多模态自演化谱系中独特的一支：别的（VisPlay/MM-Zero/Agent0-VL）靠角色互验或工具，SpatialEvo 靠**物理客观性**。它直接回应了 R-Few、SpatialEvo 等揭示的"自演化伪标签强化错误"问题，证明在有客观 oracle 的域（几何）自演化可零噪声，呼应 CUDA Agent/GrandCode"有可靠 verifier 才能反超"的精神。

#73 Memory Intelligence Agent (MIA) 📄 [华东师大 SII, 58↑] — arXiv 2604.04503 [分类⑤]

问题动机：deep research agent (DRA) 的记忆机制有两顽疾——现有方法靠检索相似过去轨迹辅助推理，但存在**记忆进化无效**（记忆不随使用变好）+ **存储/检索成本递增**（轨迹越积越慢越贵）。

核心方法：MIA 提出 **Manager-Planner-Executor** 三组件架构：**Memory Manager**（非参数记忆系统）存压缩历史搜索轨迹；**Planner**（参数记忆 agent）针对问题生成搜索计划；**Executor** 在计划引导下检索分析。训练用 alternating RL 提升协作。最关键的是 **bidirectional memory conversion loop**（参数↔非参数记忆双向转换循环）——非参数记忆（轨迹）可蒸馏进参数记忆（Planner 能力），反之亦然，循环实现高效记忆演化；Planner 支持推理时 on-the-fly 演化 + reflection/unsupervised judgment 支持开放世界自演化。

关键结果：在 11 个基准上展示优越性。786★。

意义：MIA 把"记忆进化 + 自主演化"用于 deep research agent——它的 **参/非参记忆双向转换**是记忆演化机制的有趣探索（既能把轨迹蒸成能力、也能把能力外化）。它与 memory/ 专题同一工作交叉（[memory/00-summary](#) A 类），与 MemSkill（记忆 skill 进化）、TaskMem（记忆策略学习）共同代表本库"记忆进化"分类。它把记忆从"被动检索"做成"运行时检索 + 双向演化"，呼应 GAM"记忆=运行时重构"主线。

#78 CORAL: Towards Autonomous Multi-Agent Evolution for Open-Ended Discovery 📄 [MIT, 55↑] — arXiv 2604.01658 [分类⑥]

问题动机：LLM-based 进化是开放式发现的有前景路线，但现有方法仍重度依赖固定 **heuristics** 和硬编码探索规则，限制了 LLM agent 的自主性。

核心方法：**CORAL** 是首个开放式问题上的自主多 agent 进化框架，用 long-running agents 替代僵化控制。三机制：① **共享持久记忆**——agent 跨运行积累复用知识；② **异步多 agent 执行**——多个 agent 并发共进化（而非锁步）；③ **heartbeat 干预**——周期性 check-in 允许不靠硬编码规则的方向修正。配套工程保障：隔离工作区、evaluator 分离、资源/会话/健康管理。

关键结果：在数学/算法/系统优化任务上——**10 个任务上新 SOTA**；比固定进化搜索基线**改进率高 3–10x**、所需评估次数少得多；在 Anthropic 的 kernel 工程任务上，四个共进化 agent 把最佳分从 **1363** 改进到 **1103 cycles**。代码 github.com/Human-Agent-Society/CORAL。

意义：CORAL 把多 agent 进化推向"自主、开放式、长程"——它的创新是用 long-running agents + 共享持久记忆 + 异步执行 + heartbeat 干预**取代固定 heuristics/硬编码规则**，提升自主性。它与 OneManCompany（组织级）、Hyperagents（元进化）共同代表"进化单位上移到多 agent 协同/开放式发现"。其"3-10x 改进率、更少评估"也呼应方向⁸"低成本"，1363→1103 的 kernel 优化是真实发现价值的体现。720★。

#82 Externalization in LLM Agents: A Unified Review of Memory, Skills, Protocols and Harness Engineering 📄 [上交, 52↑] — arXiv 2604.08224 [分类⑧]

问题动机：LLM agent 越来越不是靠改权重，而是靠**重组 runtime**——把能力外部化为 memory / skill / protocol / harness。但这些 agent 基础设施各自为政，缺乏统一理论解释它们的关系。

核心方法：本文用 **externalization**（外部化）作为统一透镜回顾 agent 基础设施（借 cognitive artifacts 思想）：**memory** 把状态跨时间外部化、**skills** 把程序性专长外部化、**protocols** 把交互外部化、**harness** 是协调它们的统一层。核心论点——agent 基建之所以重要，是因为它把"难的认知负担"转化为模型能更可靠解决的形式。提出"从 **weights** → **context** → **harness**"的历史演进主线（agent 能力承载从"训进权重"转向"放进上下文"再转向"放进 harness"）。

关键结果：提供 externalization 统一框架 + "weights→context→harness"演进史观。

意义：本文为本库"**frozen model + 外部状态进化**"主线提供理论框架——它把 09-skillsvote（skill 治理）、HF SkillOpt（text-space skill 优化）、SkillAdaptor、OpenSkill 等"不改权重、进化外部状态"的工作统一在"externalization"概念下。它与 memory/ 专题同一工作交叉（memory/10-externalization-efficiency），与两篇 agentic 综述（21-agentic-reasoning-survey agent 视角、22-agentic-env-survey 环境视角）形成第三个"外部化视角"，共同为整个 evolve 主题提供完整学术坐标系。

其"weights→context→harness"史观精确解释了为什么 2026 H1 自演化越来越靠外部 skill/记忆/harness。

2026-05（6 篇）

#6 SkillOpt: Executive Strategy for Self-Evolving Agent Skills 🔗 [Microsoft, 227↑] — arXiv 2605.23904 → 已在 huggingface/03-skillopt.md 精读 [分类②]

问题动机：在 frozen（闭源 frontier）模型时代，权重不可得——如何把 agent skill 当作外部状态来"训练"、系统化地优化它？现有 skill 优化多靠直觉调参，缺乏系统、可控的方法。

核心方法：SkillOpt 是首个系统化、可控的 **text-space skill** 优化器——把 skill 当作 frozen agent 的外部状态来"训练"。把 SGD 整套机制搬到文本空间：**optimizer model** 把 scored rollout 转成 **bounded add/delete/replace** 编辑，**validation gate** 严格筛选每次编辑；配 **textual learning-rate budget**（控制每次改多少）+ **rejected-edit buffer**（记录被拒编辑）+ **slow/meta update**（慢/元更新）。即把"text-space skill 优化"做成有学习率、有验证门、有动量的优化过程。

关键结果：6 基准 × 7 模型 × 3 harness = 52/52 全胜。5.8k★。

意义： SkillOpt 是本库"自然语言文档派"skill 进化的代表——把 SGD 的优化机制（学习率、验证、动量）系统地搬到文本空间，52/52 全胜证明跨模型/harness/基准均迁移。它与 [09-skillsvote](#)（治理）、HF SkillClaw（生态）、SkillAdaptor（step 级）、OpenSkill（开放世界）共同构成"frozen model + 外部 skill 进化"主线。详见 [huggingface/03-skillopt.md](#)，本库索引交叉引用。它把"skill 优化"从直觉调参升级为可控的优化过程，是该方向工程成熟度的标志。

#16 From Context to Skills: Can Language Models Learn from Context Skillfully? (Ctx2Skill) 📖 [166↑] — arXiv 2604.27660 → 精读 [08-ctx2skill](#) [分类②]

问题动机： 很多任务需 LM 在超出参数知识的上下文上推理（context learning）。把上下文转成自然语言 skill 是一条路，但两个障碍：为密集上下文手工标注 skill 成本高 + 缺乏外部反馈来自动构造 skill。

核心方法： Ctx2Skill 是无监督、无外部反馈的自演化框架——发现、精炼、选择 skill 都"无需人类监督或外部反馈"。三方自博弈：Challenger（产探测任务与 rubric）+ Reasoner（用演化的 skill 集求解）+ Judge（中立 agent 给二元反馈，自造反馈）。双向进化：Challenger 与 Reasoner 都通过累积 skill 进化，专门的 Proposer + Generator agent 分析失败案例、为双方合成定向 skill 更新。Cross-time Replay——对抗"adversarial collapse"（任务越来越极端、skill 过度专化）：选择在 Reasoner 侧代表性案例上表现最均衡的 skill 集，促进可泛化进化。skill 模型无关（可插任意 LM）。

关键结果： 在 CL-bench 四个 context learning 任务上跨 backbone 一致提升 solving rate；进化出的 skill 可插任意 LM。294★。

意义： Ctx2Skill 是本库"防对抗崩溃"主线的代表——它的 Cross-time Replay 专门解决三方自博弈中"任务越来越极端、skill 过度专化"的崩溃问题（选最均衡 skill 集）。它的"无监督无外部反馈三方自博弈（Challenger-Reasoner-Judge）"是自造反馈的代表，与 SCOPE（自判 rubric）、UniCorn（Proposer-Solver-Judge）同源。它直接对应趋势方向 [4](#) "防对抗崩溃成标配"。精读见 [08-ctx2skill](#)。

#30 SkillsVote: Lifecycle Governance of Agent Skills from Collection, Recommendation to Evolution 📖 [记忆张量, 126↑] — arXiv 2605.18401 → 精读 [09-skillsvote](#) [分类②]

问题动机： 长程 LLM agent 留下的轨迹本可成为可复用经验，但 raw 轨迹噪声大、难治理；开放 skill 生态含冗余、不均、环境敏感的产物，无差别更新会污染未来 context。

核心方法： SkillsVote 是 skill 的全生命周期治理框架——从采集到推荐到进化。① Collection——对 million 级开源语料做"环境需求/质量/可验证性"三维画像（3D profiling），合成可验证 skill 任务；② Recommendation（执行前）——agentic library search 在结构化 skill 库上搜索、控制暴露给 agent 的 skill context；③ Evolution（执行后）——把轨迹分解为 skill-linked 子任务，只把成功可复用的发

现纳入 **evidence-gated update**（证据门控更新）防污染。精细归因：把成败归到 **skill 使用 / agent 探索 / 环境 / 结果** 四因素。

关键结果：离线进化 Terminal-Bench 2.0 (GPT-5.2) **+7.9pp**；在线进化 SWE-Bench Pro **+2.6pp**。
frozen agent 不更权重也能变强。277★。44 页。

意义：SkillsVote 把"单 skill 进化"升级到"**skill 生态治理**"——它的关键贡献是 **evidence-gated update 防污染**（开放 skill 生态会被低质内容污染，必须门控）和**精细四因素归因**。它是本库"治理 skill"趋势（关键词从"产生"转向"治理"）的旗帜，证明 frozen agent 靠治理好的外部 skill 库也能变强（控制曝光、归因、保留）。它与 **08-ctx2skill**（防崩溃）、PSN（maturity gating）共同代表本库"防污染/防崩溃"主线（方向 **2/4**）。精读见 **09-skillsvote**。

#37 Skill1: Unified Evolution of Skill-Augmented Agents via Reinforcement Learning 📖 [112↑] — arXiv 2605.06130 → 精读 **06-skill1**〔分类②〕

问题动机：持久 skill 库让 agent 跨任务复用成功策略，但维护它需要三个**耦合能力**——选择相关 skill、执行时利用 skill、从经验蒸馏新 skill。如何用**一个 RL 框架**统一这三者？

核心方法：**Skill1** 用**单一 policy + 单一 task-outcome** 信号统一协同进化 skill 的**选择/使用/蒸馏**三能力。流程：agent 生成查询搜 skill 库 → 重排选最相关 → 条件求解 → 成功后蒸馏新技能加库。核心：从单一信号按**频率分解 credit**——**低频趋势归因"选择"**（找对 skill 就赢的低频任务）、**高频变化归因"蒸馏"**（创造新 skill 解锁的高频任务）。把整个 skill lifecycle 用一个 reward 信号统一驱动。

关键结果：ALFWorld / WebShop 超 skill-based 与 RL 基线；训练动态证实三能力 **co-evolve**。

意义：Skill1 避免"skill selector/executor/extractor 各训各的"碎片化——把 skill lifecycle 用一个 reward 统一。它的"按频率分解 credit"（低频→选择、高频→蒸馏）是优雅的信用分配设计。它是 Skill 进化神经 RL 派代表，与 **05-skillrl**（递归进化）、SAGE 一脉。它也是 agentic-rl 专题 **agentic-rl/00-summary** 的同一工作。精读见 **06-skill1**。

#78 Co-Evolving Policy Distillation (CoPD) 📖 [67↑] — arXiv 2604.27083〔分类③〕

问题动机：把多个专家能力整合进单一模型，RLVR 与 OPD（On-Policy Distillation）两条路各有能力损失：**mixed RLVR** 有"inter-capability divergence cost"（能力间分歧代价）；**先训专家再 OPD** 避开了分歧，但因师生行为模式差距大而"无法完全吸收 teacher 能力"。

核心方法：**CoPD** 的核心：① **并行专家训练**（专家并发训而非串行）；② **在持续 RLVR 过程中就引入 OPD**（distillation 发生在每个专家正在进行的 **RLVR 训练**中，而非训完之后）；③ **双向 OPD**——专家互为师生，distillation 双向流动实现 co-evolve；结果是在保留互补知识的同时保持行为模式一致。

关键结果：实现 **text、image、video 推理的 all-in-one 整合**，显著超过 mixed RLVR、MOPD 等强基线，甚至超过领域专家模型。作者认为并行训练模式"可能启发新的训练 scaling 范式"。

意义：CoPD 把"co-evolution"用于**多专家能力的单模型整合**——避免能力损失。它的创新是"在 RLVR 过程中就双向 OPD"（专家互为师生、边训边蒸），而非"先训完再单向蒸馏"。它属本库演化式优化/共进化分类，与本库 co-evolution 主线（出题↔解题、skill↔policy、agent↔环境）一脉，但对象是"多个专家能力"。它对多模态统一模型（text/image/video）的整合有直接价值，呼应趋势 方向³ "co-evolution 取代单向训练"。

#88 Self-Improving Language Models with Bidirectional Evolutionary Search (BES) 📖 [Harvard, 59↑] — arXiv 2605.28814 [分类③]

问题动机：search 是自改进 LM 的有效方法，但 best-of-N 和树搜索有两个根本局限：① **受稀疏验证信号引导**；② **主要靠自回归扩展构造候选**，把探索局限在高概率质量区域（model probability mass）。

核心方法：**BES (Bidirectional Evolutionary Search)** 耦合前向候选进化与后向目标分解。前向搜索——在标准扩展之上加**进化算子重组部分轨迹**，生成"单次 model rollout 难以获得的候选"（跳出高概率区）；后向搜索——递归把原任务分解为可检查的子目标（**checkable subgoals**），产生密集中间反馈引导前向搜索。理论动机：扩展-only 候选被困在"窄熵壳（narrow entropy shell）"，进化算子能逃逸；后向搜索能**指数级减少找到正确答案所需的样本数**。

关键结果：在主流后训练算法无法提升的挑战性后训练任务上，BES 实现一致增益；在 3 个开放问题求解基准（推理时），BES 在平均和最佳性能上都超过现有开源框架。153★。

意义：BES 把**进化算子注入 LLM 自改进搜索**，突破自回归扩展的探索局限（窄熵壳）——这是它对 best-of-N/树搜索两大局限（稀疏信号 + 高概率区局限）的针对性破解。它属本库演化式优化派，与 13-cse、15-gigaev0、TTT-Discover 共享"进化算子"思想，但独特在于"前向进化 + 后向分解"双向耦合 + 理论分析（熵壳逃逸、指数样本减少）。它呼应趋势 方向⁵ "自演化理论化"（给出可证明的样本复杂度结果）。

2026-06（7 篇）

#14 EvoArena: Tracking Memory Evolution for Robust LLM Agents in Dynamic Environments 📖 [MIT, 90↑] — arXiv 2606.13681 → 精读 18-evoarena [分类⑤]

问题动机：现有 agent 评测多假设**静态环境**——但真实部署中环境**渐进变化**（软件更新、社交规则演变、终端状态迁移）。agent 的记忆必须能记录并适应这种演化，否则会用过时记忆做错误决策。

核心方法：**EvoArena** 把环境变化建模为 **terminal/software/social 三域的渐进 update 序列**（一系列对环境结构化改动）——这是**首个把"环境随时间演化"作为核心评测维度的基准**。配套 **EvoMem**——

patch-based 记忆，以**结构化 update history** 记录记忆演化（每次环境变化作为一个 patch 追加），让 agent 通过"记忆变化"推理"环境演化"。

关键结果：现有 agent 在 EvoArena 仅 **39.6%**；EvoMem 在 **GAIA +6.1%**、**LoCoMo +4.8%**、**chain-level +3.7%**。

意义：EvoArena 指出了被忽视的评测盲区——**真实环境是动态的，记忆必须记录演化**。它把 working memory 研究从"静态环境管理上下文"推进到"动态环境追踪并适应变化"。它与 memory/ 专题同一工作交叉（[memory/08-evoarena-evomem](#)）。它是本库"环境从背景变一等公民"（方向7）与"动态评测"（方向7 评测侧）的代表，证明现有 agent 在演化环境上仅 39.6%——静态基准已不足以衡量。精读见 [18-evoarena](#)。

#34 Agentic Environment Engineering for LLMs: A Survey 📖 [中科院, 58↑] — arXiv 2606.12191 → 精读 [22-agentic-env-survey](#) [分类⑧]

问题动机：环境是 LLM agent 跨场景的交互系统，对驱动模型能力持续进化至关重要，但现有工作缺乏系统性分类与深度分析。

核心方法：本综述（中科院，15 作者，63 页）通过**环境工程生命周期**透镜研究该领域——**Modeling**（用 8 属性 × 8 领域刻画代表性环境）→ **Synthesis**（symbolic 与 neural 两种自动合成范式）→ **Evaluation**（与合成范式对应的评估方法）→ **Application**（通过 agent-environment co-evolution）。提出 agent 进化四路径：**memory-centric**（经验进化）/ **orchestration-centric**（ workflow 进化）/ **trajectory-centric**（离线进化）/ **exploration-centric**（在线进化）——几乎完美覆盖本库所有论文。环境演化三范式：**neural-driven** / **difficulty-driven** / **scaling-driven**。明确的 open problems：**Environment-as-a-Service (EaaS)**、**Multi-agent Environments**、**Neural-Symbolic Environments**。

关键结果：提供环境工程的完整生命周期框架 + 四进化路径 + 三演化范式 + 未来方向。

意义：本综述是本库的学术坐标系之二（环境视角）——与 [21-agentic-reasoning-survey](#)（agent 视角）互补，共同为整个 evolve 主题定调。它的**四进化路径**

（memory/orchestration/trajectory/exploration-centric）和**三环境演化范式**（neural/difficulty/scaling-driven）是本库分类与趋势分析的权威依据。它明确提出的 **EaaS**、**Neural-Symbolic**、**Multi-agent Environments** 正是本库趋势 方向3/4 的来源。精读见 [22-agentic-env-survey](#)。

#66 Task-Focused Memorization for Multimodal Agents (TaskMem) 📖 [字节 Seed, 38↑] — arXiv 2605.31075 [分类⑤]

问题动机：多模态 agent（如具身 agent）持续感知/推理/行动，面对**无界的多模态观察流**——核心挑战不是记忆模块设计，而是**determine what to memorize**（决定该记什么）：从信息的组合爆炸中选择性

保留"与角色相关、对未来任务有价值"的内容。

核心方法：TaskMem 把记忆生成重构为可学习的 memorization policy (记忆策略)，是 RL 框架，让策略动态调整关注点匹配真实任务需求。两阶段：① **Phase One (学怎么记)** ——基本保真度下优化记忆质量；② **Phase Two (学该记什么，部署后)** ——在 base MLLM 上 tune adapter，用近期环境任务定义 reward model 引导记忆策略偏向任务相关内容。评测把 VideoMME/EgoLife/EgoTempo 重构成流式基准 (问题只能用记忆答、不能看原始视频)。

关键结果：基于 Qwen3-VL-30B-A3B，三个基准 VQA 准确率 **+6.3% / +7.0% / +5.3%**。

意义：TaskMem 把"记忆 = 可学习策略"用于多模态持续学习——它明确把"该记什么"建模成可学习的 memorization policy，"部署后用近期任务定义 reward"实现任务自适应。它与 02-evocua (字节) 同源工业线，与 memory/ 专题同一工作交叉 (memory/00-summary E 类)，与 MemSkill (记忆 skill 进化) 共同代表本库"记忆进化"分类。它把记忆写入策略由 RL 学习并扩展到多模态/具身场景，呼应"进化单位上移到记忆" (方向⁶)。

#70 SkillAdaptor: Self-Adapting Skills for LLM Agents from Trajectories [蚂蚁集团, 36↑] — arXiv 2606.01311 [分类②]

问题动机：现有 training-free skill 适配从整条轨迹/会话级反馈更新 skill，失败归因太粗——产生不稳定、过宽的修订 (明明只是某一步错，却把整条经验都改了)。

核心方法：SkillAdaptor 是 training-free 的 step 级 skill 自适应框架，带显式失败归因。给定失败轨迹：① 定位"首个可操作的故障步" (first actionable fault step)；② 把责任链接到候选 skill；③ 在显式接受检查 (acceptance checks) 下做定向更新；④ 保持 backbone 冻结。可插入 OpenClaw 类 agent harness。

关键结果：在 WebShop / PinchBench / Claw-Eval 上用 Kimi-K2.5 / GLM-5 / GPT-5.2 评测，超过 no-skill 与 skill-adaptation 基线——PinchBench +1.5、Claw-Eval +1.8、WebShop +1.7。代码 github.com/zjunlp/SkillAdaptor。

意义：SkillAdaptor 把 09-skillsvote 的"精细归因 + 门控"做到 step 级 (定位首个可操作故障步)，frozen backbone。它解决了"整轨迹级归因太粗导致过宽修订"问题——step 级归因支持更稳定、可审计的 training-free skill 维护。它与 SkillsVote (生命周期治理)、SkillOpt (text-space 优化) 共同代表"frozen model + 外部 skill 精细进化"，是本库"防污染/精细归因"主线在 step 粒度的推进，可插 OpenClaw harness 也呼应 agentic-rl 的 OpenClaw-RL。

#90 Language Models Need Sleep: Learning to Self-Modify and Consolidate Memories 📄 [Google, 29↑] — arXiv 2606.03979 [分类⑤]

问题动机：现有模型缺乏持续学习、缺乏把临时 in-context 知识迁移到长期参数的能力。人类靠睡眠把短期记忆巩固成长期记忆——LLM 能否也有"睡眠"阶段？

核心方法：受人类学习启发，提出 "Sleep" 范式让模型 **self-modify**：① **Memory Consolidation**——把脆弱的短期记忆经 **replay** 蒸馏进稳定的长期参数知识（其中 Knowledge Seeding 是"小自我→大网络"的向上蒸馏）；② "**Dreaming**"——递归自我改进（RL 自生成课程自我精进）。整个过程是 agent 在"清醒"交互之外的"离线巩固"阶段。

关键结果：作为 proof-of-concept，展示短期记忆向长期参数巩固的可行性。29★。

意义：Sleep 范式触及深刻问题——短期记忆（in-context）与长期记忆（参数）之间的巩固边界。它把"睡眠巩固"这一生物学机制引入 LLM，是 03-agent-world DreamGym（reasoning-based experience model）之外又一"梦境/巩固"思路（Google 出品）。它与 memory/ 专题同一工作交叉（memory/00-summary E 类）。它属本库"记忆进化"分类，"经验→权重巩固 + 自我修改"也呼应 方向⑨ "递归/元自改进"（Dreaming 是自生成课程的自我精进）。虽仍是 proof-of-concept，但指向"经验如何沉淀为长期参数"的根本问题。

#94 SCOPE: Self-Play via Co-Evolving Policies for Open-Ended Tasks 📄 [28↑] — arXiv 2605.31433 [分类①]

问题动机：self-play 能无外部监督训练 LM，但现有方法需可规则核验的答案——开放式任务只能靠 curated prompt 或 frontier judge（贵且依赖外部）。如何在开放式任务上做无数据 self-play？

核心方法：SCOPE 是开放式任务的 data-free self-play 框架，co-evolve 两个 policy：Challenger（产文档锚定（document-grounded）的任务）+ Solver（多轮检索作答）。关键是用初始模型的冻结副本作 self-judge——它从源文档写 task-specific rubric 并据此给 Solver 打分（无需 curated 答案或 frontier judge，故 data-free）。co-evolve Challenger 是必要的——让任务保持在 Solver 能力边缘。

关键结果：3 个 7-8B 模型（Qwen2.5/Qwen3/OLMo-3）开放式性能（8 基准）最高 +10.4 分，匹敌/超过用 ~9K curated 数据训的 GRPO；虽只在开放式任务训，held-out 短答案 QA（7 基准）也最高 +13.8 分，在所有三个模型上超过 GRPO。Ablation：co-evolve Challenger 必要、增益来自检索与合成两者、rubric 生成质量是自判瓶颈。

意义：SCOPE 把自演化推到"开放式 + 无数据"——它的创新是用"初始模型冻结副本从源文档写 rubric 自判"绕过"开放式任务需 curated 答案/frontier judge"的障碍。它与 08-ctx2skill（三方自博弈）、UniCorn（Proposer-Solver-Judge）、ArenaRL（相对排名）共同探索"开放式任务如何获得可靠奖励信号"。它证明 data-free self-play 能匹敌用 9K 数据的 GRPO（甚至迁移到短答案 QA），是本库"开放世界 bootstrap"主线（方向⑩）的代表。

#95 OpenSkill: Open-World Self-Evolution for LLM Agents [OpenLAIR, 27↑] — arXiv 2606.06741 [分类②]

问题动机：现有自演化假设有可用的学习循环（curated skill / 成功轨迹 / verifier 信号），但真实开放世界可能什么都没有——只给一个任务 prompt。如何在"无 verifier、无成功轨迹"的最难场景自演化？

核心方法：OpenSkill 研究 open-world self-evolution——agent 必须从零自建 skill 与验证信号，用开放世界资源但无目标任务监督。三阶段：① 从文档/仓库/web 获取 grounded 知识 + 验证锚点（verification anchors）；② 合成可迁移 skill；③ 在自建虚拟任务上精炼，这些任务锚定在 anchor 而非目标答案上。关键洞察：开放世界同时提供"要学的知识"和"监督无关的练习环境"，目标任务监督只留作最终评估。

关键结果：3 个基准 × 2 个目标 agent，在满足无监督约束下达**最佳自动 pass rate**；skill 跨模型迁移无需模型特定适配；自建 verifier 与 ground-truth 结果对齐（尽管从未访问 ground truth）。代码 github.com/OpenLAIR/OpenSkill。20 页。

意义：OpenSkill 把自演化推到"无监督、无 verifier"的最难场景——open-world bootstrap。它的创新是 agent 从 web/文档/仓库自建验证锚点（而非依赖给定 verifier），且自建 verifier 竟与真实结果对齐。它是本库"zero-data / open-world bootstrap"主线（趋势 方向¹ "自造数据推到极限"、方向¹⁰）的最激进代表——连验证信号都自己造。它与 SCOPE（自判 rubric）、ArenaRL（相对排名）共同回答"开放世界如何自造学习循环"，但 OpenSkill 设定最极端（什么都没有）。48★。

二、2025-11 ~ 2026-06 Agent Evolve 关键趋势

1 "Zero-Data / 自造数据 / Open-World Bootstrap"成为主旋律

- 从 01-agent0（零数据双 agent）、04-dreamgym（经验合成）、02-evocua（合成 CUA 经验）到 03-agent-world（合成环境）
- top-100 扩展后更密集：MM-Zero（零数据 VLM）、SCOPE（无数据开放式 self-play）、OpenSkill（无 verifier 开放世界自建学习循环）把"自造"推到极限
- 共同信念：人类高质量数据快耗尽，agent 必须学会自己造课程/经验/环境，甚至自造验证信号

2 Skill 进化是最密集的战场（13 篇）

- 三大流派并立：
 - 神经 RL 派：05-skillrl SkillRL、06-skill1 Skill1（skill 库与 policy 共进化）、SAGE、SkillOrchestra
 - 程序化派：07-psn PSN（可执行符号程序网络）

- 自然语言文档派：09-skillsvote SkillsVote、HF SkillOpt、HF SkillClaw、SkillAdaptor、OpenSkill
- 关键词从"产生 skill"转向**"治理 skill"** (09-skillsvote evidence-gated update 防污染)

3 Co-Evolution（协同进化）取代单向训练

- 01-agent0 curriculum↔executor、05-skillrl skill库↔policy、03-agent-world agent↔环境、08-ctx2skill 出题↔解题
- 共性：两个主体互相驱动、互相施压——本质是"GAN 思路"在 agent 训练的各种变体

4 "防对抗崩溃 / 防污染"成为自演化系统的标配模块

- 08-ctx2skill Cross-time Replay、09-skillsvote evidence-gated update、07-psn maturity-aware gating + rollback
- 自演化系统的稳定性问题被正面解决——这是从"能演化"到"稳定演化"的成熟标志

5 LLM × 进化算法（遗传操作）持续升温

- 13-cse CSE（代码）、14-quantaalpha QuantaAlpha（金融）、15-gigaevo GigaEvo（AlphaEvolve 开源）、BES（双向进化搜索）、TTT-Discover（测试时进化发现）、CoPD（共进化蒸馏）
- 共性：把变异/交叉从盲目随机升级为反馈引导的受控演化；轨迹级操作 + 经验复用

6 进化的"单位"在不断上移

- 单能力（推理）→ skill → 工具（Test-Time Tool Evolution）→ 环境/课程 → 记忆（18-evoarena、MemSkill）→ 组织（19-onemancompany）→ agent 设计 agent（Memento-Skills）→ 自指元进化（Hyperagents）
- 从"一个 agent 变强"扩展到"整个 agent 生态/组织、乃至 agent 的学习机制本身随经验变强"

7 环境从"背景"变成"一等公民"

- 03-agent-world 环境自合成、16-autoenv 跨环境学习、18-evoarena 环境演化评测、22-agentic-env-survey 环境工程生命周期、SWE-Universe（百万级可验证环境）、SpatialEvo（确定性几何环境）
- 共识：环境是驱动能力持续进化的关键——不能只优化模型

8 两篇综述定调（agent 视角 + 环境视角），第三篇补"外部化"视角

- 21-agentic-reasoning-survey（UIUC，1月）：能力分层框架，确立 self-evolving layer

- [22-agentic-env-survey](#) (中科院, 6月): 环境生命周期 + 四条进化路径
- Externalization 综述 (上交, 4月): memory/skill/protocol/harness 的"外部化"统一视角
- 多篇综述为整个 evolve 主题提供完整学术坐标系

9 Frozen Model + 外部状态进化

- 闭源 frontier 模型时代, 权重不可得 → 进化外部 skill / 记忆 / 课程 / 工具
- [09-skillsvote](#)、HF SkillOpt、SkillAdaptor、OpenSkill、Externalization 综述 证明: 不更新权重也能让 frozen agent 持续变强

10 "失败"成为被重视的养料

- [02-evocua](#) 失败轨迹转富监督、[13-cse](#) 记成功+失败经验、[20-proda](#) 失败驱动数据修复、UI-Voyager (从失败经验学习)、SkillAdaptor (首个可操作故障步定位)
- 演化系统不再丢弃失败——失败包含"能力边界"的最有价值信息

11 自演化向多模态 / 空间 / GUI 全面扩散 (top-100 新增主线)

- VLM: Agent0-VL、VisPlay、MM-Zero、UniCORN; 空间: SpatialEvo; GUI: UI-Voyager、Step-GUI
- 共性: 把文本域验证成熟的自演化范式 (双/多角色 self-play、零数据) 移植到新模态, 并各自解决模态特有难题 (如 SpatialEvo 用确定性几何破伪标签自我强化)

12 元 (meta) / 自指自改进成为新前沿

- Hyperagents (Darwin Gödel Machine 思路, task agent + meta agent 自指)、Memento-Skills (agent 设计 agent)、Language Models Need Sleep (自我修改 + 巩固)
- 共性: 不只改进"解题能力", 而是改进"改进能力本身"——递归自我改进 (recursive self-improvement) 的早期探索

三、研究发展现状与方向趋势

3.1 发展现状: 八个月走过的三个阶段 (top-100 视角, 50 篇)

把 2025-11 ~ 2026-06 的 50 篇按时间铺开, "agent evolve"主题清晰地走过了三个阶段:

2025-11

① 萌芽/单点突破

• Agent0 零数据

• DreamGym 经验合成

• GigaEvo 开源基建

• AutoEnv 跨环境学习基准

• Agent0-VL/VisPlay 自演化扩散到 VLM

2026-01/02

② 范式确立+扩散

• Agentic Reasoning 综述确立 self-evolving layer

• SkillRL/PSN/CSE/QuantaAlpha 各流派

• 向多模态扩散 (MM-Zero/UniCORN)

• R-Few 诊断自演化塌缩

2026-03/04

③ 体系化/治理/元进化/最新前沿

• SkillsVote skill 治理

• Skill1 统一 credit

• EvoArena 记忆/环境演化评测

• Hyperagents 自指元进化

• Memento 设计 agent

• Need Sleep 自我修改

• OpenSkill 开放世界 bootstrap

• Agentic Env 综述收束

2026-05/06

• 阶段① (2025-11~12) 单点突破 + 初步扩散: 01-agent0、04-dreamgym 证明"零数据/合成经验自演化"可行; 同期 Agent0-VL/VisPlay 已把范式扩到 VLM; 12 月 R-Few 率先诊断"自演化塌缩"。

• 阶段② (2026-01~02) 范式确立 + 多模态扩散: 21-agentic-reasoning-survey 综述确立 self-evolving layer; 三大流派代表作密集出现; MM-Zero/UniCORN 把零数据自演化推广到多模态; SWE-Universe 把环境推到百万级。

• 阶段③ (2026-03~06) 体系化 + 治理 + 元进化 + 最新前沿: 关键词从"能不能进化"转向"如何稳定、可治理、可递归地进化"——09-skillsvote 治理、08-ctx2skill 防崩溃、Hyperagents/Memento 元进化、Need Sleep 自我修改、OpenSkill 开放世界 bootstrap、22-agentic-env-survey 综述收束。

当前成熟度判断:

- 已解决 (从研究角度): ① 零数据/合成数据自演化的可行性 (含多模态); ② skill 作为能力载体的三种实现路径; ③ co-evolution 的基本稳定性 (防崩溃/防污染门控); ④ 自演化向 VLM/空间/GUI 的可移植性。
- 正在解决: ① 自演化的可治理性 (09-skillsvote、R-Few); ② 动态环境下的记忆/评测 (18-evoarena、MemSkill); ③ 进化单位向组织级 / agent 设计 agent / 元进化扩展 (19-onemancompany、Memento、Hyperagents); ④ 开放世界无 verifier 的 bootstrap (OpenSkill、SCOPE)。
- 尚未解决: 见下 3.3。

3.2 现状的四条主线 (横切视角)

主线	现状	代表
数据来源	从"人工标注"→"自造课程/经验/环境"→"开放世界自造验证信号"已基本完成范式切换	01-agent0 04-dreamgym 03-agent-

主线	现状	代表
		world OpenSkill
能力载体	skill 成为主流载体，三流派（神经/程序化/文档）并立；并扩展到工具、记忆	05-skillrl 07-psn 09-skillsvote MemSkill
进化机制	co-evolution + 防崩溃/防污染门控 成为标准架构；元进化/自指开始出现	08-ctx2skill 06-skill1 Hyperagents
适用模态	从文本扩散到 VLM / 空间 / GUI，各解模态特有难题	Agent0-VL MM-Zero SpatialEvo UI-Voyager

3.3 未来方向趋势（基于 50 篇的缺口与多篇综述的展望）

综合本库论文的局限（见各篇第 4 节）+ [21-agentic-reasoning-survey](#) / [22-agentic-env-survey](#) 等综述明确提出的 open problems。

方向 1：从"单任务/单域演化"走向"终身、跨域演化（Lifelong & Cross-domain）"

- 现状：多数工作仍在单域（ALFWorld/WebShop/OSWorld）内演化；[16-autoenv](#) 已揭示跨环境学习几乎未被解决（7 个 LM 只拿 12-49%）。
- 趋势：真正的 lifelong learning——agent 在持续变化的多域环境里不遗忘、可迁移。[18-evoarena](#) 的"演化链评测"是第一步。

方向 2：自演化的"可治理性 / 安全性 / 对齐"成为必答题

- 现状：[09-skillsvote](#) 已把"治理"独立出来；[21-agentic-reasoning-survey](#) 明确把 **governance** 列为未来方向。
- 趋势：当 agent 能自主进化能力，如何防止能力漂移、目标偏移、skill 库被恶意/低质内容污染会成为核心议题——evidence-gated / validation-gate 只是开始。

方向 3：进化"单位"继续上移——从组织到多组织生态

- 现状：进化单位已从 能力→skill→环境→记忆→组织（[19-onemancompany](#)）。
- 趋势：[22-agentic-env-survey](#) 提出 **Multi-agent Environments**；下一步是多 agent 组织/市场级别的协同进化——agent 之间形成分工、交易、竞争的演化生态。

方向 4：Environment-as-a-Service（环境即服务）+ Neural-Symbolic 环境

- 现状：[03-agent-world](#) 用 MCP 接入真实环境已是雏形；[22-agentic-env-survey](#) 明确提出 EaaS 与 Neural-Symbolic 环境。
- 趋势：环境像云服务一样**可按需合成、计费、复用**；符号（可验证）与神经（可生成）环境融合，兼顾保真度与多样性。

方向 [5](#)：自演化的"理论化"——可证明的收敛性与稳定性

- 现状：[07-psn](#) 发现"skill 进化 $\approx$ 神经网络训练"的同构，HF SkillOpt 把 SGD 搬到文本空间——都还是**经验类比**，缺乏理论保证。
- 趋势：把文本/符号空间的演化与优化理论对接，给出**收敛性、稳定性、样本复杂度**的可证明结果——这是该领域从"工程"走向"科学"的关键。

方向 [6](#)：World Model 与自演化深度融合

- 现状：[04-dreamgym](#) 的"reasoning-based experience model"本质是轻量 world model；[21-agentic-reasoning-survey](#) 把 **world modeling** 列为深水区。
- 趋势：用更强的 world model 生成更真实的"想象经验"，让 agent 在"脑内沙盘"里大规模演化——sim-to-real 的保真度是关键瓶颈。

方向 [7](#)：评测体系跟上——动态、演化、经济价值导向

- 现状：[18-evoarena](#) 揭示现有 agent 在动态环境仅 39.6%；静态基准（GAIA/HLE）已饱和。
- 趋势：评测从"静态难题"转向"**持续演化 + 真实经济价值**"（呼应 huggingface 库的 Agents' Last Exam）——能否在不断变化的真实环境里**持续保持能力**，成为新标尺。

方向 [8](#)：效率与成本——让自演化"用得起"

- 现状：[02-evocua](#) 数万 sandbox rollout、[14-quantaalpha](#) 依赖 GPT-5.2、co-evolution 算力高——**门槛是普及的最大障碍**。
- 趋势：[04-dreamgym](#) 的"合成 warm-start + 少量真实 RL"、frozen model + 外部状态进化（[09-skillsvote](#)、SkillAdaptor）等**低成本路径**会持续受重视；training-free 演化是重要补充。

方向 [9](#)：递归 / 元自改进（Recursive & Meta Self-Improvement）——从"改能力"到"改改进机制"

- 现状：Hyperagents（Darwin Gödel Machine 思路）已指出"自我改进能力在 coding 域外难对齐"；Memento-Skills 让 agent 设计 agent；Need Sleep 让模型自我修改、巩固。
- 趋势：真正的递归自我改进——agent 不只解题、还改进自己的学习算法/元机制。这是通往"超级智能"叙事的核心，也是最难、最具风险的方向（[21-agentic-reasoning-survey](#) 列为深水区）。

方向 [10](#)：开放世界 Bootstrap + 自演化的稳定性理论统一

- 现状：OpenSkill/SCOPE 把自演化推到"无 verifier、无成功轨迹、只给 prompt"的开放世界；但 R-Few、08-ctx2skill、Guided Self-Evolving 都揭示无引导自演化会塌缩（concept drift / diversity collapse / mis-evolution）。
- 趋势：把"开放世界自造学习循环"与"防塌缩稳定性"统一——需要既能自举又不退化的机制。这是"自造数据"主线走到尽头后的必答题。

3.4 一句话总结现状与方向

现状：2026 H1 的 agent evolve 已完成"从能不能进化 → 各流派范式确立 + 向多模态/空间/GUI 全面扩散 → 稳定可治理地进化 + 元进化萌芽"的三级跳；**skill 进化 + co-evolution + 防崩溃门控**是已成型的主流配方，**zero-data / open-world bootstrap**是最激进的前沿。

方向：下一阶段的胜负手在 ① 终身跨域、② 可治理/可对齐、③ 进化单位上移到生态/元机制、④ 环境即服务、⑤ 理论化、⑥ world model 融合、⑦ 动态评测、⑧ 低成本、⑨ 递归/元自改进、⑩ 开放世界 bootstrap + 防塌缩——谁能把"自演化"做得又稳、又省、又可控、还能自我递归，谁就能定义 2026 H2 乃至通向 superintelligence 的范式。

四、文档说明

- 每篇 📖 精读笔记含 5 个标准章节：① 为什么重要 ② 核心方法 ③ 关键实验结果 ④ 对领域的影响/后续方向 ⑤ 资源
- 📄 简述论文在本文件按月给出 3-4 行要点，未单独建 md；条目末标注〔分类①~⑧〕对应开头分类表
- 🔗 标记的论文（SkillClaw / SkillOpt）已在 huggingface/ 目录精读，本库只做索引与交叉引用
- **数据范围：**每月 top-100；📖 精读为原 top-50 的 14 篇核心工作，📄 简述含 top-50 的 6 篇 + top-100 扩展的 28 篇
- 想建立全景：先读两篇综述 [21-agentic-reasoning-survey](#) + [22-agentic-env-survey](#)，再按分类读各专题